

Master in Human Centered Computing

- Masterthesis -

# Artefaktkorrektur und verfeinerte Qualitätsmetriken für ein EEG-basiertes System zur Müdigkeitserkennung

vorgelegt von:

Paul Pasler, 751325

paul.pasler@student.reutlingen-university.de

vorgelegt am:

05.04.2017

geprüft von:

Prof. Dr.-Ing. habil. Natividad Martínez Madrid

Prof. Dr.-Ing. Cristóbal Curio



*Für Viola und Fritz.*



## Vorwort

Das Thema Müdigkeit im Straßenverkehr beschäftigt mich nun schon eine ganze Weile. Bevor ich mit meinen Studien begonnen habe, waren Systeme zur Müdigkeitserkennung nur eines von vielen Hilfen im Auto. Während der Bearbeitung bekam ich einen Eindruck vom Potential eines solchen Systems und den Möglichkeiten auch außerhalb des Straßenverkehrs.

An der Umsetzung reizte mich die Kombination verschiedener Informatikbereiche, wie zum Beispiel Signalverarbeitung, Machine-Learning und Softwaretechnik. Außerdem war ich gespannt auf die Schnittstellen zu anderen Domänen, welche unter anderem Medizin und Elektrotechnik umfassen.

Die Arbeit mit einem EEG war eine besondere Herausforderung und gerade zu Beginn mit einigen Hürden verbunden.

An dieser Stelle möchte ich mich beim Service der Fakultät Informatik für die Unterstützung bedanken. Stellvertretend sei Emre Yay genannt, der mir eine Einführung in den hochschuleigenen Simulator und das EEG-Headset gegeben hat.

Ein weiteres Dankeschön gilt den Teilnehmern der durchgeführten Experimente. Ohne die Probanden gäbe es keine Daten und auch keine Masterthesis.

Alles in allem war es ein sehr interessantes Projekt und ich hoffe, dass weitere Forschungen in diesem Bereich nachfolgen werden.

---

Paul Pasler



# Inhaltsverzeichnis

## i. Abbildungsverzeichnis

## ii. Tabellenverzeichnis

## iii. Abkürzungsverzeichnis

<b>1. Einführung</b>	<b>1</b>
1.1. Müdigkeit . . . . .	1
1.2. Ziel . . . . .	2
<b>2. Stand der Technik</b>	<b>5</b>
2.1. Bewertung . . . . .	8
<b>3. Methodik</b>	<b>13</b>
3.1. Hardware . . . . .	13
3.1.1. EEG EPOC+ . . . . .	13
3.1.2. Fahrsimulator . . . . .	15
3.2. Software . . . . .	17
3.2.1. Emokit . . . . .	17
3.2.2. MNE Python . . . . .	18
3.3. Testdatenerhebung . . . . .	18
3.3.1. Ziel . . . . .	19
3.3.2. Versuchsaufbau . . . . .	19
3.3.3. Durchführung . . . . .	20
3.4. Independent Component Analysis . . . . .	22
3.4.1. Problemstellung . . . . .	22
3.4.2. Mathematisches Modell . . . . .	25
3.4.3. Algorithmus . . . . .	26
3.4.4. Topomap . . . . .	28
3.5. Künstliches Neuronales Netz . . . . .	29
<b>4. Erweiterung der PoSDBoS-Anwendung</b>	<b>33</b>
4.1. Anwendungsübersicht . . . . .	33
4.2. Rohdatenakquise . . . . .	36
4.3. Vorverarbeitung . . . . .	37
4.4. Artefaktkorrektur . . . . .	38
4.5. Qualitätsmetriken . . . . .	42

4.6. Merkmalsextraktion . . . . .	44
4.7. Klassifizierung . . . . .	46
4.8. Ausgabe . . . . .	47
<b>5. Ergebnis</b>	<b>49</b>
5.1. Experiment . . . . .	49
5.2. Müdigkeitserkennung . . . . .	52
5.3. Vergleich zur ursprünglichen Implementierung . . . . .	56
5.4. Diskussion . . . . .	57
5.5. Ausblick . . . . .	58
<b>6. Fazit</b>	<b>61</b>
<b>7. Anhang</b>	<b>63</b>
7.1. Fragebogen: Vor dem Experiment . . . . .	64
7.2. Fragebogen: Nach dem Experiment . . . . .	65
7.3. Architektur Fahrsimulator . . . . .	66
<b>8. Literaturverzeichnis</b>	<b>67</b>
<b>9. Ehrenwörtliche Erklärung</b>	<b>77</b>

## i Abbildungsverzeichnis

1.1.	Modell zur Übermüdung . . . . .	2
1.2.	Müdigkeitserkennung bei VW . . . . .	3
1.3.	Problemstellung Müdigkeitserkennung . . . . .	3
1.4.	Komponenten des Systems zur Müdigkeitserkennung . . . . .	4
3.1.	Medizinisches EEG / EMOTIV Epoch . . . . .	14
3.2.	EEG Sensoranordnung . . . . .	14
3.3.	Simulator Fahrerkabine . . . . .	16
3.4.	Simulator Monitoring-Cockpit . . . . .	16
3.5.	Versuchsaufbau Experiment . . . . .	20
3.6.	Szenario Testfahrt . . . . .	22
3.7.	Cocktailparty Effekt . . . . .	23
3.8.	ICA für Hirnwellen . . . . .	24
3.9.	ICA Flowchart . . . . .	26
3.10.	Geometrische Interpretation der ICA . . . . .	27
3.11.	ICA Topomap . . . . .	29
3.12.	Schema eines Perceptrons . . . . .	29
3.13.	Beispiel Lineare Separierbarkeit . . . . .	30
3.14.	Schema eines Multi Layer Perceptrons . . . . .	30
4.1.	Package- und Klassenstruktur . . . . .	34
4.2.	Verarbeitung einer EEG-Sequenz . . . . .	35

4.3. Übertragungsmöglichkeiten einer EEG-Sequenz . . . . .	36
4.4. Datenstrukturen . . . . .	37
4.5. Datenaufbereitungskette . . . . .	38
4.6. Artefakte in EEG Signalen . . . . .	39
4.7. EEG-Signale mit EOG Artefakt . . . . .	40
4.8. Auswirkungen von EOG-Artefakten . . . . .	40
4.9. Videobild zur Validierung von EOG-Artefakten . . . . .	41
4.10. Topomap zur Validierung von EOG-Artefakten . . . . .	42
4.11. EEG-Signal mit Kopfbewegung . . . . .	43
4.12. EEG-Signal ohne Kopfbewegung . . . . .	43
4.13. Boxplot der EEG-Signale . . . . .	45
5.1. Boxplot für Geschwindigkeit und Lenkbewegung . . . . .	51
5.2. Boxplot für Gyroskopwerte . . . . .	51
5.3. Datensetaufteilung in „Wach“ und „Müde“ . . . . .	53

## ii Tabellenverzeichnis

2.1. Ansätze zur Erkennung von Müdigkeit . . . . .	5
2.2. Vergleichstabelle Müdigkeitserkennung . . . . .	11
3.1. Experimentparameter . . . . .	21
4.1. KNN Parameter . . . . .	47
4.2. Status des Müdigkeitsmonitors . . . . .	47
5.1. Probanden . . . . .	50
5.2. Ergebnisse: Qualität und Klassifizierung . . . . .	54
5.3. Ergebnisse: Monitor . . . . .	55
5.4. Ergebnisse ursprüngliche Implementierung . . . . .	56
5.5. Alte und neue Verarbeitungsparameter . . . . .	57
5.6. Ergebnisse mit neuer Verarbeitungskette . . . . .	57



### iii Abkürzungsverzeichnis

**Abb.** Abbildung

**Tab.** Tabelle

**Abs.** Abschnitt

**PoSDBoS** Portable System to Detect Driver Drowsiness with Body Sensors . . . . . 4

**EEG** Elektroenzephalogramm . . . . . 4

**EKG** Elektrokardiogramm . . . . . 4

**EOG** Elektrookulogramm . . . . . 6

**EMG** Elektromyogramm . . . . . 39

**PERCLOS** The percentage of eyelid closure over the pupil over time

**WPT** Wavelet Packet Transformation . . . . . 6

**HRV** Heart Rate Variability . . . . . 6

**PPG** Photoplethysmogramm . . . . . 6

**GSR** Galvanic skin response . . . . . 6

**SVM** Support Vector Machine . . . . . 6

**LDA** Lineare Diskriminanzanalyse . . . . . 7

**QRS-Komplex** Gruppe von Ausschlägen im EKG

**KNN** Künstliches Neuronales Netz . . . . . 6

**FFT** Fast Fourier Transformation . . . . . 9

<b>ICA</b> Independent Component Analysis.....	7
<b>PSD</b> Power Spectral Density .....	7
<b>HMM</b> Hidden Markov Modell .....	7
<b>LR</b> Lineares Regressionsmodell.....	7
<b>CAN-Bus</b> Controller Area Network-Bus.....	17
<b>KSS</b> Karolinska sleepiness scale.....	19
<b>BSS</b> Blind Source Separation.....	22
<b>PCA</b> Principal Component Analysis.....	22
<b>IC</b> Independent Component.....	24
<b>P1</b> Drei Probanden aus dem aktuellen Experiment	
<b>P2</b> Fünf Probanden aus dem vorherigen Experiment	
<b>P3</b> Zwei Probanden aus P1 und drei aus P2	
<b>DS1</b> Trainingsdatensatz von P3	
<b>DS2</b> Trainingsdatensatz von drei Probanden aus P2	
<b>KNN2</b> KNN aus dem vorherigen PoSDBoS System, trainiert mit DS2	
<b>KNN3</b> KNN aus dem aktuellen PoSDBoS System, jedoch trainiert mit DS2	

# 1 Einführung

Müdigkeit ist ein unterschätztes, aber dennoch großes Problem im Straßenverkehr. Von rund 2,5 Millionen Verkehrsunfällen 2015 in Deutschland [Bun15a], waren 2.898 Unfälle, mit insgesamt 59 Toten (~1,7% der Todesfälle), auf Übermüdung zurückzuführen [Bun15b]. Schätzungen gehen jedoch von einer Dunkelziffer von bis zu 20% aus [Eve08, Ake00]. Oft werden diverse Fahrfehler als offizielle Unfallursache angegeben, welche jedoch ursächlich auf einen übermüdeten Fahrer zurückzuführen sind. Bei diesen Unfällen handelt es sich zudem überdurchschnittlich häufig um schwere Unfälle mit Personenschäden. Zu betrachten sind nicht nur Autounfälle durch Sekundenschlaf, sondern auch solche, die durch eine verlängerte Reaktionszeit oder Fehleinschätzungen von Gefahrensituationen herbeigeführt werden. Um den Fahrer rechtzeitig vor solchen Situationen zu warnen und diese zu verhindern, wurde die vorgestellte Forschungsarbeit durchgeführt.

Der folgende Abschnitt definiert Müdigkeit und zeigt, welche Anzeichen und Gegenmaßnahmen es gibt. In Abschnitt 1.2 wird das Ziel der Arbeit ausformuliert.

## 1.1 Müdigkeit

Müdigkeit beschreibt den subjektiven Zustand einer Person, der im allgemeinen mit dem Verlangen nach Schlaf umschrieben werden kann. Sie wird häufig mit Übermüdung oder Schläfrigkeit synonym verwendet. Im englischen Sprachgebrauch kann Müdigkeit mit *drowsiness, fatigue oder sleepiness* [Joh98] übersetzt werden. Auch die erste Stufe der *non rapid eye movement (NREM)* Schlafphase wird als *drowsy* (im deutschen *leichter Schlaf*) bezeichnet [BBM<sup>+</sup>12]. Diese Phase bildet den Übergang vom Wach- in den Schlafzustand.

In dieser Arbeit wird die Definition aus Stedman's Medical Dictionary [Ste08] verwendet. Dort wird Müdigkeit als *das Verlangen bzw. die Neigung einzuschlafen* beschrieben. Diese Neigung kann durch schlechten oder wenig Schlaf, hohe oder aber auch zu niedrige mentale Anstrengung ausgelöst werden [Ake00, oDFS98]. May und Baldwin entwickelten hierzu ein Modell (siehe Abb.1.1 [MB09]). Sie unterteilten die Müdigkeitsursachen in solche, die mit Schlaf (*sleep-related, SR*) oder der derzeitigen Aufgabe (*task-related, TR*) zusammenhängen. Beides führt zu einer

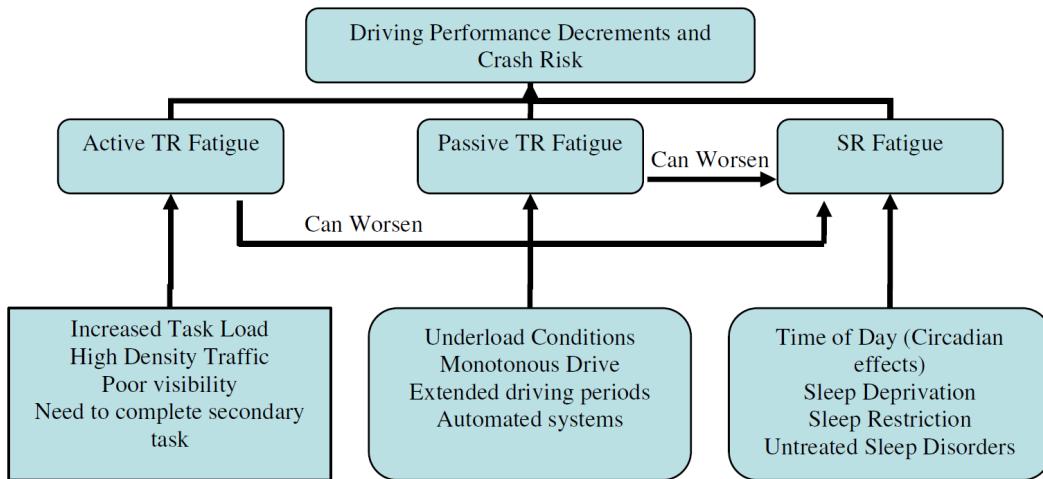


Abb. 1.1.: Verschiedene Ursachen führen zu TR- oder SR-Müdigkeit und am Ende zu einem erhöhten Unfallrisiko. Sie können sich gegenseitig beeinflussen bzw. verstärken.

Verminderung der Fahrtüchtigkeit und erhöht somit das Unfallrisiko. Egal welche Gründe für eine durch Übermüdung hervorgerufene, verminderte Aufmerksamkeit vorliegen, die Folgen sollen durch ein System zur Müdigkeitserkennung deutlich gesenkt werden. Objektive Anzeichen von Müdigkeit sind laut der National Sleep Foundation [Nat16]: häufiges Blinzeln und Gähnen, Probleme den Kopf oben zu halten und Abkommen von der Spur mit heftigem Gegenlenken. Der sogenannte Sekundenschlaf ist die gefährlichste Folge von Übermüdung im Straßenverkehr. Der ADAC [e.V16] rät darum sich nur ausgeschlafen ins Fahrzeug zu steigen und auf Alkohol zu verzichten. Erkennt man an sich selbst Anzeichen von Übermüdung, sollte die Fahrt unmittelbar unterbrochen werden. Unabhängig davon wird grundsätzlich nach ca. zwei Stunden eine Fahrpause empfohlen.

Nachdem Müdigkeit definiert wurde, folgt im nächsten Abschnitt die Problemstellung und das Ziel der Arbeit.

## 1.2 Ziel

Die Müdigkeitserkennung soll dem Fahrer eine erkannte Gefahr durch Übermüdung möglichst früh melden. So hat er genügend Zeit, eine geeignete Stelle für einen Pausenplatz zu finden und sich zu erholen. Dadurch kann die Zahl schwerer Unfälle aufgrund von Müdigkeit gesenkt werden.

Müdigkeitserkennung zählt zu den sogenannten Fahrerassistenzsystemen und war 2014 bereits in jedem vierten Neuwagen in Deutschland eingebaut [Gmb15]. Alle



Abb. 1.2.: Bei erkannter Müdigkeit, wird dem Fahrer bei VW ein Hinweis in der Multifunktionsanzeige eingeblendet (Bildquelle: <http://de.volkswagen.com/de/innovation-technik/techniklexikon/Muedigkeitserkennung.html>, 4. April 2017).

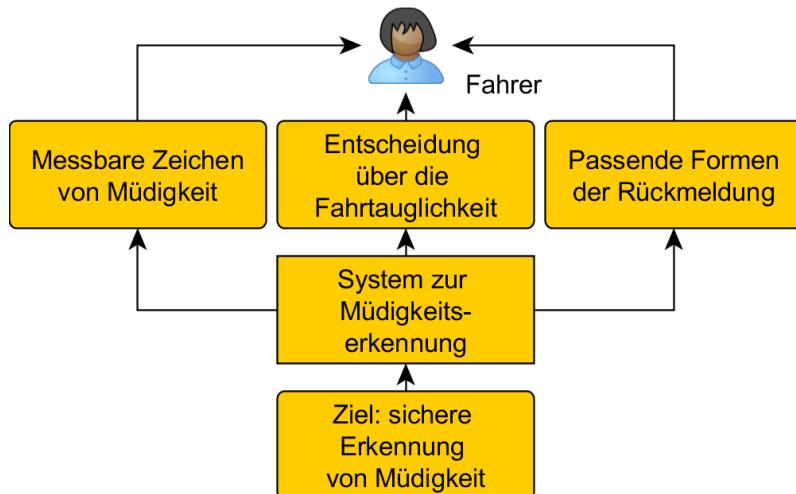


Abb. 1.3.: Um das Ziel zu erreichen, benötige man ein funktionierendes System zur Müdigkeitserkennung. Für die Lösung ergeben sich drei Teilproblemstellungen.

namhaften Automobilhersteller bieten mittlerweile derartige Systeme an. Die Müdigkeitserkennung bspw. von Volkswagen blendet dem Fahrer eine Warnung ein (siehe Abb. 1.2) und ist mittlerweile selbst in Kleinwagen erhältlich. Diese eingebauten Systeme beschränken sich meist auf die Analyse des Fahrverhaltens (siehe Kapitel 2).

Die aktuelle Forschungsarbeit hat das Ziel, *eine mögliche Müdigkeit des Fahrers, anhand von Veränderungen seiner Körpersignale, sicher zu erkennen*. Dazu müssen im ersten Schritt messbare Anzeichen von Müdigkeit definiert werden (siehe Abb. 1.3). Äußere Anzeichen dienen hierbei zur Feststellung, in welchem Zustand sich der Fahrer gerade befindet. Die Körpersignale müssen diesen Zustand widerspiegeln, sodass ein Algorithmus in der Lage ist, diese automatisch zu erkennen. Eine erkannte Übermüdung soll dem Fahrer in angemessener Weise angezeigt werden, um die Warnung wahrnehmen und entsprechend reagieren zu können.

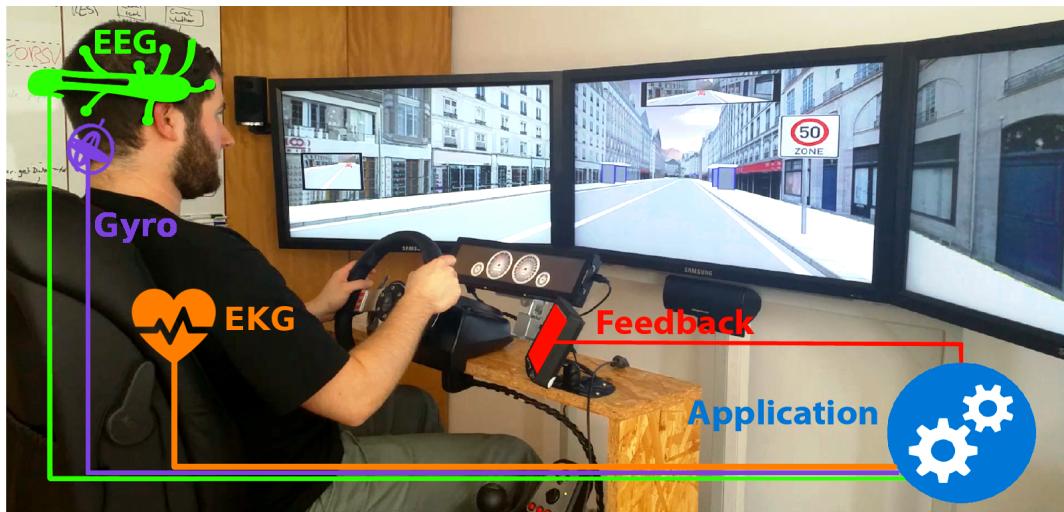


Abb. 1.4.: EEG (grün), Gyroskop (violett) und EKG Sensoren (orange) senden ihre Daten in die Anwendung (Blau) und diese entscheidet, ob der Fahrer eine Warnung auf dem Monitor (Rot) erhält.

Grundlage ist die zuvor, im Rahmen des Masterprojekts, entwickelte Anwendung *Portable System to Detect Driver Drowsiness with Body Sensors* (PoSDBoS) [Pas16], die mit einem *Elektroenzephalogramm* (EEG) arbeitet. Die Erkennungsrate und letztlich die Genauigkeit des Systems sollen im Rahmen der Arbeit erhöht werden. Die zu beantwortende Frage ist, ob diese Verbesserung durch eine *Artefaktkorrektur und verfeinerte Qualitätsmetriken* erreicht werden kann. Live und Trainingsdaten sollen, ohne manuelles Selektieren, automatisch analysiert werden können. Zur Stabilisierung der Anwendung werden weitere Sensoren, wie ein Gyroskop und ein *Elektrokardiogramm* (EKG) hinzugezogen. Abbildung 1.4 zeigt die Komponenten des Systems.

Im vorherigen Abschnitt wurde die Zielsetzung erläutert. Zuvor waren die Motivation für ein System zur Müdigkeitserkennung und die Definition von Müdigkeit Thema. Die Masterthesis gliedert sich wie folgt: In Kapitel 2 werden aktuelle Forschungsergebnisse zum Thema Müdigkeitserkennung analysiert und verglichen. Kapitel 3 beschreibt eingesetzte Hard- und Software, das Experiment zur Datenakquise, sowie die eingesetzten Methoden. Die PoSDBoS-Anwendung und ihre Funktionsweise sind Thema des darauffolgenden Kapitels (4). Die Ergebnisse und das Fazit werden in den Kapiteln 5 und 6 beleuchtet.

## 2 Stand der Technik

Systeme zur Müdigkeitserkennung lassen sich in 3 Kategorien einteilen. Durch eine Analyse des Fahrverhaltens, von visuellen Anzeichen (Computer Vision, CV) oder von Körpersignalen wird jeweils versucht auf den Zustand des Fahrers zu schließen (siehe Tab. 2.1). Im Folgenden werden aktuelle Forschungsarbeiten zum Thema Müdigkeitserkennung dargestellt. Im darauffolgenden Abschnitt werden diese Arbeiten bewertet und führen zu den Anforderungen an das PoSDBoS-System.

<b>Fahrverhalten</b>	Lenkverhalten, Spurhalten, Geschwindigkeit
<b>Visuelle Anzeichen</b>	Blinzelrate (PERCLOS), Kopfpose
<b>Körpersignale</b>	EEG, EKG, EOG

Tab. 2.1.: Ansätze zur Erkennung von Müdigkeit

Die Analyse des Fahrverhaltens ist die häufigste verbaute Variante bei Automobilherstellern. Der *ATTENTION ASSIST* von Mercedes Benz [Ben16] wertet die Lenkbewegungen (Lenkmoment, -winkel und -geschwindigkeit), die Fahrzeuglängs- und Querbeschleunigung, sowie Bediengriffe des Fahrers aus und kombiniert diese Werte mit weiteren Umgebungsparametern wie der Tageszeit oder der Fahrtzeit. Für jeden Fahrer wird während einer 20-minütigen Initialisierungsphase ein individuelles Fahrerprofil erstellt. Auf dieser Basis gibt das System einen Aufmerksamkeitswert auf einer fünfstufigen Skala von niedrig bis hoch. Volkswagen und Bosch nutzen einen ähnlichen Ansatz [Vol16, Gmb12]. Da es sich um interne Entwicklungen handelt, sind detailliertere Informationen nicht zu finden. Lui et al. [LHL09] führten für ältere Studien ein Review durch, konnten aber keine eindeutigen Ergebnisse präsentieren. Sie stellten grundsätzlich in Frage, ob die Ergebnisse der durchgeführten Studien allgemein übertragbar seien. Moller et al. [MKB<sup>+</sup>06] führten eigene Versuche mit 34 Probanden durch und kombinierten Fahrverhalten (Spurhalten, Geschwindigkeit) mit Körpersignalen. Die Kombination lieferte bessere Ergebnisse, als das Fahrverhalten alleine. Einen weiteren Ansatz ohne im Fahrzeug verbaute Sensoren verfolgten Lee et al. [LLC16]. Sie nutzen Gyroskop und Beschleunigungssensor einer Smartwatch und schlossen daraus auf die Lenkbewegung. Müdigkeit wurde zu 98% erkannt.

Toyota ist einer der wenigen Automobilhersteller, der sich für eine Analyse von visuellen Anzeichen entschieden hat [Toy08]. Bei dieser wird der Fahrer mit einer Kamera überwacht und im Videobild nach Anzeichen von Müdigkeit gesucht. Dazu gehören unter anderem Blinzeln, die Kopfposition und Gähnen. Ein häufig eingesetztes Maß für Müdigkeit ist der sogenannte PERCLOS-Wert (percentage of eyelid closure over the pupil over time). Dieser gibt das Verhältnis von offenen zu geschlossenen Augen in einem bestimmten Zeitabschnitt an. Dabei geht es weniger um kurzes Blinzeln, als um das längere Zufallen der Augen. Wierwille et al. [WF-Kea94] befanden PERCLOS für das stabilste und eindeutigste optische Mittel zur Erkennung von Müdigkeit. Es wurde eine Metrik entwickelt, die besagt, wenn die Augen zu 80% pro Minute geschlossen sind, es ein deutliches Zeichen für Müdigkeit darstellt (P80). Yan et al. [YKLL16] nutzten diesen Mechanismus, um aus einem Graustufenbild den PERCLOS-Wert zu berechnen und erreichten eine Augenerkennung im Bild von 92%. Sie führten zudem Versuche mit Probanden durch, die eine Brille trugen. Zhang et al. [ZLT15] nutzen neben einem Farbbild auch ein Tiefenbild (RGB-D), um die Kopfpose und den Augenstatus zu erkennen. Hierfür wurde eine Kinect Kamera eingesetzt. Der Augenstatus wurde von einer *Support Vector Machine* (SVM) klassifiziert und zu 96% erkannt. Sie führten zudem Versuche mit verrauschten Bildern durch und hatten immer noch eine Erkennungsrate von 82%. You et al. [YLC<sup>+</sup>13] implementierten ihre Anwendung als Smartphone-App. Sie nutzen beide Kameras (Vorder- und Rückseite) des Smartphones und erkannten neben Müdigkeit auch weitere gefährliche Situationen (bspw. zu dichtes Auffahren). Übermüdung wurde bei 6 Versuchspersonen zu 60% erkannt. Bergasa et al. [BNS<sup>+</sup>06] erweiterten das PERCLOS um weitere Features und nutzten eine Infrarot-LED zur Bildgebung. Bei Experimenten wurde eine Erkennungsrate von 93% erreicht. Probleme zeigten sich bei direkter Sonneneinstrahlung und beim Tragen von Brillen.

Unabhängig von den Lichtverhältnissen sind Systeme mit Körpersensoren. Hierbei werden Körpersignale aufgenommen, um daraus Schlüsse auf den Zustand des Fahrers zu ziehen. Dazu werden hauptsächlich das EEG, EKG oder *Elektrookulogramm* (EOG) genutzt. Weitere, eher selten verwendeten Verfahren, nutzen ein *Photoplethysmogramm* (PPG) [POH09], auch *Pulsoxymetrie* genannt, oder die *elektrodermale Aktivität* (*Galvanic skin response* (GSR)) [BB09]. Sari et al. [SH16] verwendeten ein PPG und den Puls, um daraus auf die *Heart Rate Variability* (HRV) zu schließen. Die *Wavelet Packet Transformation* (WPT) und ein „fuzzy“ *Künstliches Neuronales Netz* (KNN) legten, nach eigenen Angaben, mit sieben Testpersonen eine gute Grundlage für weitere Studien. Ebenfalls vielversprechende Zwischenergebnisse erreichten Singh et al. [SSTA16] mit einem EKG Sensor, der sich am Lenkrad befand und somit nicht am Körper angebracht werden musste.

---

Vicente et al. [VLBB11] errechneten aus einem EKG Signal die HRV. Hierzu kamen zwei Datenbanken zum Einsatz, die jeweils mit Hilfe von Videoaufnahmen gelabelt wurden. Die *Lineare Diskriminanzanalyse* (LDA) erreichte eine Erkennungsrate von 93%. Rogado et al. [RGB<sup>+</sup>09] nutzten ebenfalls die HRV und den QRS-Komplex für eine Müdigkeitserkennung. Dazu wurden ein medizinisches EKG und zusätzlich ein EKG-Brustgurt aus dem Fitnessbereich eingesetzt. Schlussendlich konnte jedoch kein eindeutiges Ergebnis erzielt werden. Zhang et al. [ZL12] konzentrierten sich auf die Erkennung mit dem QRS-Komplex und das Pulssignal. Damit erreichten sie bei 15 Testpersonen eine nahezu hundertprozentige Erkennungsrate.

Khushaba et al. [KKLD11] führten Studien mit multimodalen Systemen in verschiedenen Kombinationen von EEG, EKG und EOG durch und verglichen die Ergebnisse. Testdaten wurden für 31 Probanden aufgenommen, welche jeweils 3 Stunden in einem Simulator fuhren. Die Signale wurde später anhand der Videoaufnahmen gelabelt. Sie fanden heraus, dass EOG und EKG alleine nicht geeignet sind Müdigkeit zu erkennen, das EEG jedoch schon. Die besten Ergebnisse ließen sich mit einem EEG und einem EKG erzielen. Lin et al. [LWL<sup>+</sup>05] führten ebenfalls Versuche mit EEG, EOG und EKG durch, nutzten für die Klassifizierung letztendlich aber nur das EEG. Mit der *Independent Component Analysis* (ICA) (siehe Abs. 3.4), der *Power Spectral Density* (PSD) und durch ein *Lineares Regressionsmodell* (LR) konnten sie eine Erkennung von 88% erreichen. Ein Jahr später stellten sie einen ähnlichen Ansatz mit einem KNN vor und steigerten die Erkennungsrate auf 94% [LKC<sup>+</sup>06]. Johnson et al. [JPO<sup>+</sup>11] führten Versuche in zwei Studien mit insgesamt 160 Personen durch. Sie nutzten ein EEG und EOG für die Akquise von Körpersignalen. Neben 45-minütigen Fahraufgaben wurden weitere kognitive Aufgaben gestellt und bewertet, um auf den Müdigkeitsgrad zu schließen. Als Feature dienten verschiedene Frequenzen der PSD. Vuckovic et al. [VRCP02] nutzen ebenfalls EEG und EOG. Im Vergleich zur Klassifizierung von EEG Experten, wurde mit ihrem System eine über neunzigprozentige Übereinstimmung erreicht. Als Feature wurde eine Abwandlung der PSD, für ein Fenster der Länge 1s, eingesetzt. Ein weiteres Ziel war die Bestimmung des besten Algorithmus zur Erstellung eines KNN. Der Learning Vector Quantization lieferte hierbei die besten Ergebnisse. Subasi et al. [Sub05] führten ähnliche Studien durch und erreichten eine Erkennungsrate von 93%. Auch sie verglichen KNN Algorithmen und befanden den *Resilient Backpropagation* für den schnellsten und genauesten Algorithmus für ein KNN. Es finden sich weitere Ansätze mit einem EEG und einem KNN [WB00, KBRD00] ohne beschriebene Ergebnisse. Huang et al. [HCTC96] nutzen ein *Hidden Markov Modell* (HMM) als Klassifikator und erreichten eine Erkennungsrate von ~70%. Belakhdar et al. [BKDO16] untersuchten bei ihren Forschungen von EEG Daten zur Müdigkeitserkennung, ob sich

hierbei ein KNN oder eine SVM besser eignet. Es wurde hierzu die Performance und die *Receiver-Operating-Characteristic-Kurve* (ROC) [Bra97] bestimmt. Bei einem einzelnen EEG Kanal eignet sich das KNN (86,5%) besser zur Erkennung von Müdigkeit, als die SVM (79%). Auch bei der Erkennung von Wachheit, erzielt das KNN bessere Ergebnisse (KNN 83,5%, SVM 68%). Die sogenannte *Area Under the Curve*, basierend auf der ROC-Kurve (*Receiver Operating Characteristic*), zeigt beim KNN einen höheren Wert.

Die Ergebnisse für Systeme mit Körpersensoren sind in Tabelle 2.2 noch einmal zusammengefasst. Die Bewertung der einzelnen Ansätze ist Thema des nächsten Abschnitts.

## 2.1 Bewertung

Die Analyse des Fahrverhaltens besticht vor allem durch ihren Komfort und die gute Vernetzung zum Fahrzeug. Sie fügt sich nahtlos in andere Sicherheitssysteme im Fahrzeug ein und wird darum gerne von Automobilherstellern verwendet. Zur Zuverlässigkeit der eingebauten Systeme liegen keine öffentlich zugänglichen Studien vor. Offene Ansätze mit Sensoren außerhalb der Fahrzeugelektronik mit Smartphones zeigen gute Ergebnisse.

Systeme mit visuellen Anzeichen, wie Blinzeln, Gähnen oder ähnlichem, kommen ebenfalls ohne Körperkontakt aus und stören den Fahrer daher nicht. PERCLOS ist eine Metrik, die sich in vielen Studien als sehr genau erwiesen hat. Jedoch muss das System dazu die Augen des Fahrers erkennen, was durch verschiedenste äußere Einflüsse gestört werden kann. Zum einen ist ein kamerabasiertes System immer optischen Grenzen unterworfen, das heißt grelles Sonnenlicht oder Dunkelheit können das Bild beeinflussen. Mützen, Bart oder Brillen, insbesondere Sonnenbrillen, erschweren die Erkennung des Gesichts und somit die Erkennung der Augen. Auch Infrarot- oder Tiefenbildkameras zeigten in den betrachteten Arbeiten einige dieser Schwächen. Die Nutzung beider Smartphonekameras ist eine interessante Erweiterung, da nicht nur der Fahrer, sondern auch die Straße beobachtet wird. So können biologische Faktoren und das Fahrverhalten gleichzeitig analysiert werden.

Körpersensorsysteme messen Körpersignale und können Veränderungen (bspw. durch Müdigkeit) somit schnellstmöglich erkennen. Sie erreichen im Vergleich zu kamera-basierten Systemen ebenso gute Ergebnisse. Durch die Vielzahl an Sensoren liegt

ein breites Spektrum an Untersuchungen vor. Arbeiten mit PPG und GSR sind eher seltener zu finden, könnten aber durch ihre einfache Handhabung und Tragekomfort in Zukunft häufiger eingesetzt werden. Die bisherigen Ergebnisse sind jedoch eher unzureichend. Bessere Erkennungsraten zeigen EKG-Sensoren, welche in den betrachteten Arbeiten, Müdigkeit in über 90% der Fälle richtig klassifizieren. Jedoch finden sich auch Artikel, die mit dem EKG als einzigen Sensor keine brauchbaren Ergebnisse erhalten. Im Einsatz sind medizinische EKGs mit drei Ableitungen. Für das EKG, aber auch PPG, wird meist die HRV als Feature genutzt.

Das EEG wird häufig auch als Goldstandard [JPO<sup>+11</sup>] für die Erkennung von Müdigkeit bezeichnet. Bei der Recherche fanden sich in diesem Bereich die meisten Forschungsarbeiten mit vielversprechenden Ergebnissen. Die Zustände „Wach“, „Müde“ und „Schlafend“ lassen sich sehr gut erkennen, sodass die Erkennungsraten meistens über 90% liegen. In den betrachteten Arbeiten kommen meist medizinische EEGs (siehe Abb. 3.1, links) mit 14 bis 64 Sensoren zum Einsatz. Das EEG wird häufig zusammen mit einem EOG eingesetzt - letztendlich handelt es sich hierbei um zwei weitere EEG-Sensoren, die neben den Augen platziert werden. Das EOG zeichnet unter anderem Blinzeln auf und somit könnte auch der PERCLOS-Wert als zusätzliches Feature berechnet werden. Die Verbindungen von EEG, EKG und EOG zu einem multimodalen System sind ebenfalls vielversprechend, da Erkenntnisse aus allen Kanälen gebündelt werden. Jedoch spielt das EEG in multimodalen Systemen meist die Hauptrolle und EKG bzw. EOG stabilisieren lediglich die Ergebnisse. Zusammenfassend lässt sich für Arbeiten mit EEG, EKG und EOG sagen, dass in fast allen Fällen der Frequenzbereich als Feature genutzt wird. Hierfür wird entweder eine *Fast Fourier Transformation* (FFT) oder eine WPT eingesetzt. Als Klassifikatoren werden unter anderem das KNN, die SVM, die LDA oder das HMM verwendet. Alle Sensoren brauchen Körperkontakt bzw. müssen direkt am Körper angebracht werden.

Über die Fahrverhaltensanalyse ist trotz ihrer Verbreitung relativ wenig öffentlich bekannt. Kamerabasierte Systeme sind nur bei freiem Gesicht und Tageslicht uneingeschränkt nutzbar. Beide Ansätze lassen sich mit einem Smartphone umsetzen. Körpersensoren liefern genaue, stabile Werte und sind von Umgebungsfaktoren mehr oder weniger unabhängig. Das EEG schneidet im Vergleich zu EKG und EOG besser ab und wird am häufigsten eingesetzt. Den meisten Körpersensoren ist gemein, dass sie den Komfort des Fahrers deutlich einschränken. Ziel ist es daher den Tragekomfort zu verbessern und die Handhabung zu vereinfachen. Mögliche Lösungsansätze sind kleinere Geräte, kabellose Sensoren, der Einbau der Sensoren

in das Fahrzeug (Lenkrad oder Sitz) oder in Gegenstände, die vom Fahrer getragen werden können (Wearables oder Smartwatch). Dieser Gesichtspunkt wurde in den Arbeiten mit Körpersensoren bisher völlig vernachlässigt. Weiterhin wurde bisher kein besonderes Augenmerk auf die Kosten der EEG und EKG Sensoren gelegt. Auch das Nutzen proprietärer Software (meist Matlab<sup>1</sup>) ist ein potentieller Kostenfaktor.

Die vorgestellte PoSDBoS-Anwendung arbeitet, aufgrund der hohen Genauigkeit, mit Körpersensoren. Ansätze mit Fahrverhaltensanalyse und visuellen Anzeichen sind zu anfällig für äußere Einflüsse. Das System nutzt ein EEG, da dies, innerhalb der Körpersensoren, die besten Ergebnisse erreicht. Es wird durch ein EKG lediglich erweitert und etwas stabilisiert. Weitere Sensordaten kommen aus dem Gyroskop und sind ein Indiz für Bewegungsartefakte. Dieses wurde in bisherigen Arbeiten nicht eingesetzt. Um die invasiven Eigenschaften, im Vergleich zu Fahrverhalten und Kamera, zu vermindern, werden besondere Sensoren eingesetzt. Die genutzten Sensorsysteme sind kabellos und leicht anzubringen, um ein größtmögliches Maß an Komfort und Mobilität zu erreichen. Um die Kosten des Systems möglichst gering zu halten, werden günstige Sensoren und freie Software eingesetzt. In vielen Studien werden die Daten zudem manuell aufbereitet und gelabelt, dies soll in der aktuellen Arbeit automatisch erfolgen.

Nachdem nun der Stand der Technik und die Besonderheiten des PoSDBoS-Systems aufgezeigt wurden, werden im folgenden Kapitel Grundlagen und benötigte Komponenten vorgestellt, welche notwendig sind, um das System zu realisieren.

---

<sup>1</sup><https://de.mathworks.com/products/matlab.html>

Ref.	Sensor	Verarb.	Merkmal	Klass.	Genauigkeit (# Probanden)
[BB09]	GSR	-	GSR / PPG	KNN	93% (10)
[POH09]	PPG	-	Puls-ausschlagshöhe	SVM	80% (5)
[SH16]	PPG	-	HRV	KNN	-
[SSTA16]	PPG	FFT	HR	KNN	- (8)
[VLBB11]	EKG	-	HRV	LDA	93% (21)
[RGB <sup>+</sup> 09]	EKG	FFT	HRV	-	-
[ZL12]	EKG	-	QRS-Komplex	SVM	~100% (15)
[Sub05]	EEG	WPT	WPT-Koeffizienten	KNN	93% (30)
[WB00]	EEG	WPT	WPT-Koeffizienten	KNN	99%
[KBRD00]	EEG	FFT	-	KNN	- (5)
[HCTC96]	EEG	FFT	Frequenz-energie	HMM	70%
[BKDO16]	EEG	FFT	Frequenz-energie	KNN, SVM	86,5%, 79% (16)
[LWL <sup>+</sup> 05]	EEG	FFT	ICA, PSD	LR	88,2% (16)
[LKC <sup>+</sup> 06]	EEG	FFT	ICA, PSD	KNN	94% (10)
[VRCP02]	EEG, EOG	FFT	PSD	KNN	94% (17)
[JPO <sup>+</sup> 11]	EEG, EOG	FFT	PSD	LDA	- (160)
[KKLD11]	EKG, EEG, EOG	WPT	HRV	LDA	97% (31)

Tab. 2.2.: Studien die Müdigkeit an Hand von Körpersignalen erkennen.



## 3 Methodik

Um ein System zur Müdigkeitserkennung zu realisieren, müssen mehrere Voraussetzungen an Hardware (Abs. 3.1) und Software (Abs. 3.2) erfüllt sein. In einem Experiment (Abs. 3.3) wurden Testdaten aufgenommen, um damit einen Klassifikator (Abs. 3.5) zu trainieren. Abschnitt 3.4 befasst sich mit Grundlagen der Independent Component Analysis, welche später zur Artefakterkennung eingesetzt wird.

### 3.1 Hardware

Für das erweiterte PoSDBoS-System werden ein Emotiv EPOC+ EEG Headset (Abs. 3.1.1), sowie ein Zephyr Bioharness 3<sup>1</sup> zur Aufnahme der Körpersignale verwendet. Die Experimente zur Testdatenakquise wurden im Fahrsimulator der Reutlingen University (Abs. 3.1.2) durchgeführt.

#### 3.1.1 EEG EPOC+

Für die Arbeit wird ein EEG Headset *Emotiv EPOC+*<sup>2</sup> mit 14 Kanälen verwendet, das seine Daten via Bluetooth überträgt. Im Vergleich zu einem medizinischen EEG ist das Headset leichter anzubringen und benötigt keine Kabel (siehe Abb. 3.1).

Das Headset tastet Hirnwellen mit einer Sampling Rate 128 oder 256Hz ab. Störsignale aus dem Stromnetz, werden durch einen Notch Filter bei 50Hz und 60Hz vermindert. Dieser wirkt sich bis ca. 45Hz aus, sodass Emotiv 43Hz als höchste ausgegebene Frequenz spezifiziert. Die Referenzelektroden befinden sich in P3 und P4 (diese liegen am Mastoid an). An P3 wird *Common Mode Sense* (CMS) als absolute Spannungsreferenz genutzt. P4 fungiert als passive *Driven Right Leg* (DRL) Elektrode, um Rückkopplungen des *Common Mode Body* Potenzials zu verhindern (siehe auch [Ins11]). Das EPOC+ besitzt zudem Inertial-Bewegungssensoren mit neun Achsen: Gyroskop, Beschleunigungsmesser und Magnetometer.

Die Sensoren sind nach dem internationalen 10-20 System [Jas58] angeordnet. Hierbei handelt es sich um eine standardisierte relative Anordnung der Elektroden.



Abb. 3.1.: Links: Ein medizinisches EEG mit 64 Kanälen und EOG-Sensor. Rechts: Das EMOTIV Epoch+ EEG Headset mit 14 Kanälen. Bildquellen:  
[https://en.wikipedia.org/wiki/File:EEG\\_cap.jpg](https://en.wikipedia.org/wiki/File:EEG_cap.jpg) und  
<https://www.emotiv.com/product/emotiv-epoch-14-channel-mobile-eeg>,  
4. April 2017

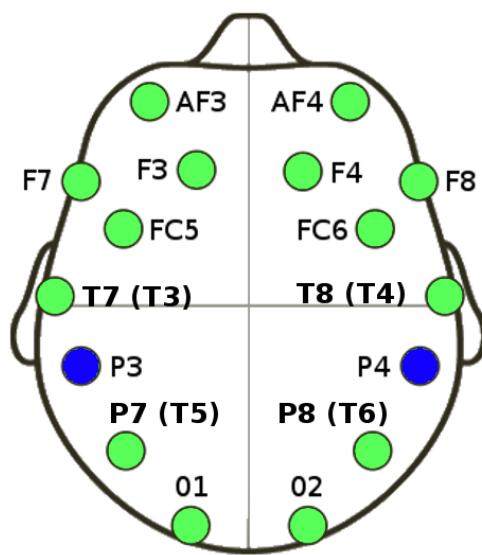


Abb. 3.2.: Die 14 Kanäle (grün), sowie die beiden Qualitätssensoren (dunkelblau).

Die Benennung der Sensoren sind aus Empfehlungen der „International Federation of Clinical Neurophysiologie“ entnommen [DE99]. Abbildung (3.2) zeigt die Bezeichnung der 14 Sensoren.

Das Headset wurde bereits in vielen wissenschaftlichen Arbeiten eingesetzt (bspw. finden sich bei *IEEE Xplore* über 70 Beiträge<sup>3</sup>). Benitez et al. [BTS16] nutzten das Headset und ein *Künstliches Neuronales Netz* (KNN) zur Zwinkererkennung. Ekanayake [Eka15] führte Versuche mit dem *oddball paradigm* durch und erhielt ein korrektes EEG Signal. Badcock et al. [BMM<sup>+</sup>13] machten Versuche mit ereigniskorrelierten Potentialen basierend auf dem Gehör (*auditory Event Related Potentials*). Sie verglichen die Ergebnisse (21 Probanden) des EPOC und eines medizinischen EEGs (Neuroscan Synamps 4.3) und stellten bei der Spitzenamplitude und bei Latenzmessungen keine signifikanten Unterschiede fest. Morillo et al. [MAGGAR16] nutzen das EPOC, um die Wirksamkeit von Werbung auf den Probanden zu testen. Dazu wurde die Hirnaktivität während kurzer Werbespots ausgewertet.

Preislich ist das Emotiv eher am unteren Rand für EEG Systeme angesiedelt. Im ähnlichen Preisniveau würden sich das NeuroSky Mindwave<sup>4</sup> oder das OpenEEG Projekt<sup>5</sup> bewegen.

Die EEG-Daten wurden im Fahrsimulator der Reutlingen University aufgenommen, dieser wird im folgenden Abschnitt näher beschrieben.

### 3.1.2 Fahrsimulator

Der Fahrsimulator besteht aus einer Fahrerkabine (siehe Abb. 3.3) und einem Monitoring-Cockpit (siehe Abb. 3.4).

Die Fahrerkabine enthält alle wichtigen Bestandteile eines normalen Fahrzeugs: Sitz, Lenkrad, Pedale, Cockpitanzeige (Touchscreen) und Simulationsbildschirme (Displays). Auf der Cockpitanzeige lassen sich Meldungen an den Fahrer senden. Sie wird von der jeweiligen Applikation gespeist. Abbildung 7.3 im Anhang zeigt

---

<sup>1</sup><https://www.zephyranywhere.com>, 4. April 2017

<sup>2</sup><https://www.emotiv.com>, 4. April 2017

<sup>3</sup><http://ieeexplore.ieee.org/search/searchresult.jsp?queryText=emotiv%20epoch>, 4. April 2017

<sup>4</sup><http://store.neurosky.com>, 4. April 2017

<sup>5</sup><http://openeeg.sourceforge.net>, 4. April 2017



Abb. 3.3.: Die Fahrerkabine mit Sitz, Lenkrad, Pedalen, Cockpitanzeige und Simulationsbildschirmen.



Abb. 3.4.: Im Monitoring-Cockpit kann das Experiment überwacht werden.

den Systemaufbau des Simulators. Er besteht aus drei Computern: *Simulation*, *DataCollector* und *Embedded*. Der Simulations-Rechner nimmt die Eingaben des Cockpits entgegen und zeigt die Simulation auf jeweils drei Bildschirmen an (Fahrerkabine und Monitoring-Cockpit). Der DataCollector holt sich die Fahrzeugdaten aus der Simulation via *TCP/IP* und legt sie auf den *Controller Area Network-Bus* (CAN-Bus). Auch die Daten externer Sensoren (EEG, EKG) werden hier gesammelt und zur Verfügung gestellt (bspw. auf dem CAN-Bus). Der Embedded PC simuliert eine kleine Recheneinheit im Fahrzeug, das seine Daten aus dem CAN-Bus erhält, Anwendungen ausführt und diese auf der Cockpitanzige darstellt. Mit dem Aufbau wird versucht die Kommunikation in einem echten Fahrzeug möglichst originalgetreu nachzubilden.

Nachdem die eingesetzte Hardware beleuchtet wurde, folgt nun eine Beschreibung der genutzten Software.

## 3.2 Software

Die vorgestellte PoSDBoS-Anwendung ist in der freien Programmiersprache *Python*<sup>6</sup> entwickelt. Python ist eine interpretierte, objektorientierte und dynamische Sprache. Für Python existieren zahlreiche freie Erweiterungen, die Funktionalitäten für wissenschaftliche Berechnungen anbieten. Mit *Numpy*, *Scipy*, *Matplotlib* bietet Python ähnliche Möglichkeiten wie bspw. *Matlab* und behält dabei alle Vorteile einer echten Programmiersprache.

In den folgenden Abschnitten wird die Kommunikation mit dem EEG-Headset (Abs. 3.2.1) und EEG-Bibliothek MNE (Abs. 3.2.2) zur Verarbeitung der EEG-Daten vorgestellt.

### 3.2.1 Emokit

Um die EEG Daten in Echtzeit zu erhalten, kann die proprietäre Software von Emotiv genutzt werden (Emotiv PURE). Diese liefert jedoch nur die Rohdaten und sendet weder die Gyroskop- noch die Signalqualitätswerte. Die freie Software *Emokit*, liefert diese Daten und lässt sich, dank der Python Implementierung,

---

<sup>6</sup><https://www.python.org/doc/essays/blurb/>, 4. April 2017

einfach in die PoSDBoS-Anwendung integrieren. Emokit wurde bereits im wissenschaftlichen Umfeld eingesetzt<sup>7</sup>.

Nachdem die Daten mit Emokit aufgenommen wurden, müssen sie weiterverarbeitet werden. Die dafür eingesetzte Software wird im folgenden Abschnitt betrachtet.

### 3.2.2 MNE Python

*MNE-Python* ist eine OpenSource-Software zur Analyse und Visualisierung von EEG und Magnetoenzephalographie (MEG) Daten. Sie wurde 2013 von Wissenschaftlern um Alexandre Gramfort vorgestellt [GLL<sup>+</sup>13] und seitdem stetig weiterentwickelt. Neben einer geeigneten Datenhaltung in Python Objekten, ist ein Import / Export in gängige Dateiformate (EEGLAB, Neuroscan CNT, European data format) möglich. Die Daten können analysiert, verarbeitet und angezeigt werden. MNE wurde bereits in mehreren wissenschaftlichen Arbeiten verwendet<sup>8</sup>.

Die eingesetzte Software und Hardware dient dem Zweck der Datenverarbeitung und Datenakquise. Das Experiment zur Testdatenerhebung ist Thema des folgenden Abschnitts.

## 3.3 Testdatenerhebung

Um Müdigkeit zu erkennen, werden im ersten Schritt Testdaten mit müden Fahrern benötigt. Diese wurden teilweise im Rahmen der Arbeit aufgenommen und erweiterten die vorhanden Datensätze aus dem Masterprojekt [Pas16].

Die Zielsetzung (Abs. 3.3.1), der Aufbau (Abs.3.3.1) und die Durchführung (Abs. 3.3.3) werden in den folgenden Abschnitten beleuchtet.

---

<sup>7</sup><https://scholar.google.de/scholar?q=%22emokit%22>, 4. April 2017

<sup>8</sup><http://martinos.org/mne/dev/cited.html>, 4. April 2017

### 3.3.1 Ziel

Ziel des Experiments ist die Provokation von Müdigkeit und deren objektive Anzeichen (siehe Abs. 1.1). Es sollen deutliche Symptome von Müdigkeit, wie häufiges Gähnen und Blinzeln, sowie Fahrfehler (Lenkverhalten, Geschwindigkeit) erzeugt werden (siehe Tab. 2.1). Die Zustände „Wach“ und „Müde“ sollen sich eindeutig unterscheiden lassen. Die erkannten Zustände dienen zur Kategorisierung der EEG Sequenzen und bilden die Basis für die Klassifizierung.

Für das Experiment werden folgende Hypothesen aufgestellt:

1. Es existieren Parameter für den Versuchsaufbau und -ablauf, die den Prozess des *Ermüdens* während des Experiments begünstigen / beschleunigen.
2. Während des Experiments sind bei den Probanden deutliche Zeichen von Müdigkeit zu erkennen (Gähnen, Fahrfehler). Diese Anzeichen spiegeln sich in den EEG und EKG Signalen wider.

Das Ziel, möglichst schnell deutliche Anzeichen von Müdigkeit zu erhalten, war Thema des vergangenen Abschnitts. Im Folgenden wird der Versuchsaufbau des Experiments erläutert.

### 3.3.2 Versuchsaufbau

Das Experiment wurde im Fahrsimulator der Reutlingen University durchgeführt. Während des Versuchs wurden das EEG und das EKG des Probanden, die Videos des Fahrers und der Fahrstrecke, sowie diverse Fahrzeugdaten (Geschwindigkeit, Lenkverhalten) aufgenommen (siehe Abb. 3.5).

Realität und Simulation unterscheiden sich naturgemäß, jedoch zeigten Engstrom et al. [EJO05] und Horne et al. [HR99], dass die Ergebnisse trotzdem valide und brauchbar sind. Dieser Einschätzung folgen Klüver [KHH<sup>+</sup>16] und De Winter [WLH12]. Kaptein et al. [KTvdH96] stellten unter anderem eine Veränderung des Risikoverhaltens fest. Dies ist für den Fall der Provokation von Müdigkeit eher hilfreich, da der natürliche Widerstand gegen das Einschlafen in einer Gefahrensituation (Autofahrt) im Simulator schwächer ausgeprägt ist.

Um zusätzlich zu objektiven Anzeichen auch eine subjektive Einschätzung der Müdigkeit zu erhalten, werden den Probanden Fragebögen vor (Anh. 7.1) und nach (Anh. 7.2) dem Experiment ausgegeben. Unter anderem werden Schlafgewohnheiten (Biorhythmus), Fahrerfahrung und der Müdigkeitsgrad, angelehnt an die *Karolinska sleepiness scale* (KSS) [KTÅ<sup>+</sup>06], abgefragt.

---

Auf den Versuchsaufbau und die erhobenen Daten, folgt die Durchführung und die Bestimmung der Experimentparameter.

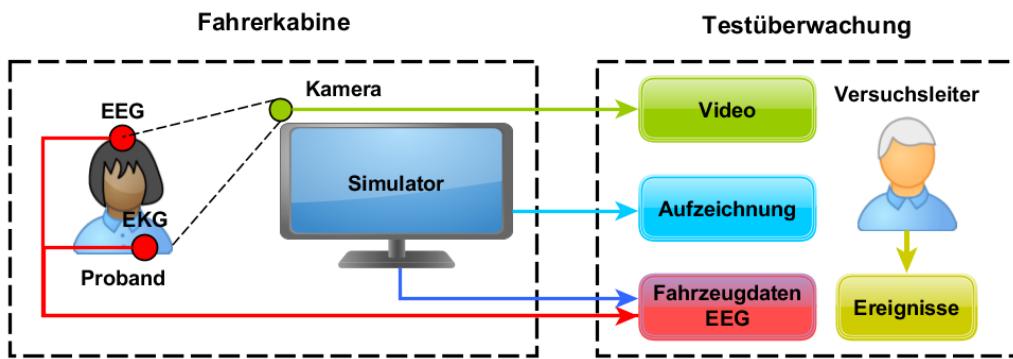


Abb. 3.5.: Der Versuchsaufbau für die Erkennung von Müdigkeit mit den Datenströmen aus dem Simulator zur Testüberwachung.

### 3.3.3 Durchführung

Für die Durchführung des Experiments, werden die Literatur und die Erkenntnisse aus den Experimenten des Masterprojekts herangezogen, um Parameter zu finden, die Müdigkeit bei den Probanden möglichst schnell erhöhen.

Aus dem Experiment des Masterprojekts lassen sich folgende Erkenntnisse ableiten: Bei den Probanden ist die Fahrerfahrung und Langstreckenübung ein nicht zu unterschätzender Faktor. Es ist anzunehmen, dass Berufskraftfahrer lange Autobahnenfahrten gewöhnt sind und somit vermutlich später Anzeichen von Müdigkeit zeigen, als bspw. ungeübte Fahreranfänger. Dies zeigten auch unterschiedlich stark ausgeprägte Anzeichen bei verschiedenen Fahrern. Weiterhin ließ sich die Hypothese aus dem Experiment - nach der die Müdigkeit während der Fahrt linear ansteigt - nur bedingt im EEG Signal nachweisen. Im vorherigen Experiment wurden die ersten und letzten 5 Minuten eines Probanden genutzt und diese Sequenzen als *Wach* und *Müde* deklariert [SSK<sup>+</sup>11]. Der Abstand müsste evtl. länger sein. Andere Arbeiten legen nahe, dass gezielt nach Kennzeichen für Müdigkeit (siehe Tab. 2.1) gesucht und die EEG-Sequenzen mit dieser Information auf ihre Tauglichkeit überprüft werden können. Die Fahrtzeit war mit 30 Minuten unter Umständen zu kurz und könnte verlängert werden. Die unerheblichen Unterschiede zwischen Anfang und Ende eines Experiments könnten durch ein zweites Referenzexperiment mit den selben Probanden verdeutlicht werden. Dieses sollte möglichst viele der in Tabelle 3.1 genannten Parameter umdrehen. Hierbei ist erneut die Übung ein zu beachtender Faktor. Kennt der Fahrer das Experiment und den Simulator bereits, könnte sich dies auf die Ergebnisse im zweiten Experiment auswirken.

Tabelle 3.1 zeigt Parameter aus der Literatur, welche eine schnelle Müdigkeitszunahme während des Experiments begünstigen können.

Parameter	Wert
Tageszeit	zwischen 2:00 - 6:00 und 14:00 - 16:00 Uhr [HR99, MKB <sup>+06</sup> ]
Fahrstrecke	monotone Strecke [TB03], Autobahn ohne andere Verkehrsteilnehmer [oDFS98], nächtliche Umgebung [HR99], insgesamt mit wenigen Ablenkungen [ABTR05]
Experimentdauer	mind. 20 Minuten [TB03] [Pas16], 45Min [JPO <sup>+11</sup> , LKC <sup>+06</sup> ], 1h [Hel13, ABTR05]
Schlafmenge	weniger als 6 Stunden Schlaf vor dem Experiment [EJO05].
Fahrer	männlich, zwischen 20 und 25 Jahren [oDFS98]

Tab. 3.1.: Experimentparameter, die schnelle Müdigkeit begünstigen.

Aus den Parametern der Literatur und den Erkenntnissen aus dem früheren Experiment, leitet sich die Durchführung des aktuellen Experiments ab:

- Die Testfahrt wird nachmittags zwischen 14:00 und 16:00 stattfinden,
- das Szenario spielt nachts auf der Autobahn ohne andere Verkehrsteilnehmer (siehe Abb. 3.6),
- das Experiment hat eine Fahrdauer von 45 Minuten,
- die Probanden sind angehalten vor dem Experiment weniger als 6 Stunden zu schlafen,
- die Auswahl der Fahrer erfolgt zufällig und erfüllt ein möglichst breites Spektrum,
- vor und nach dem Experiment erfolgt eine Befragung der Probanden.

Der vergangene Abschnitt befasste sich mit der Durchführung des Experiments. Ziel, Hypothesen und Versuchsaufbau wurden zuvor ebenfalls erläutert. In folgenden Abschnitten werden Methoden näher beleuchtet, welche in der Anwendung zum Einsatz kommen.



Abb. 3.6.: Das Autobahnszenario verläuft monoton geradeaus, spielt nachts bei konstanter Geschwindigkeit und ohne andere Verkehrsteilnehmer.

### 3.4 Independent Component Analysis

Die *Independent Component Analysis* (ICA), im deutschen auch *Unabhängigkeitsanalyse*, ist ein multivariates Verfahren, um mehrere Zufallsvariablen zugleich zu analysieren und wurde erstmals von Jutten und Herault [JH91] veröffentlicht. Sie wird unter anderem zur *Blind Source Separation* (BSS), *Merkmalsextraktion* oder *Erkennung und Entfernung von Artefakten* (Störsignale) eingesetzt. Die ICA ist verwandt mit der *Hauptkomponentenanalyse* (*Principal Component Analysis* (PCA)) [Pea01, Dun89] und der LDA. Die PCA kommt unter anderem in der Vorverarbeitung der ICA zur Anwendung.

In den folgenden Abschnitten wird die Problemstellung (Abs. 3.4.1), das mathematische Modell (Abs. 3.4.2), sowie der Algorithmus (Abs. 3.4.3) und die aus der ICA gewonnene topographische Information (Abs. 3.4.4) beschrieben.

#### 3.4.1 Problemstellung

Ein Beispiel für die BSS ist der sogenannte *Cocktailparty Effekt* [Che53]. Dieser beschreibt eine Situation, bei der sich mehrere Personen in einem Raum befinden und sich unterhalten (siehe Abb. 3.7). Das menschliche Gehör ist in der Lage, sich auf bestimmte Gespräche (Signale) zu konzentrieren und uninteressante Signale (andere Gespräche oder Störsignale) herauszufiltern. Diese Fähigkeit wird auch intelligenzes oder selektives Hören genannt. Sie funktioniert nur bei beidohrigem Hören (binauraler Effekt) und ist eng mit der Lokalisation von Schallquellen verknüpft. Mittels

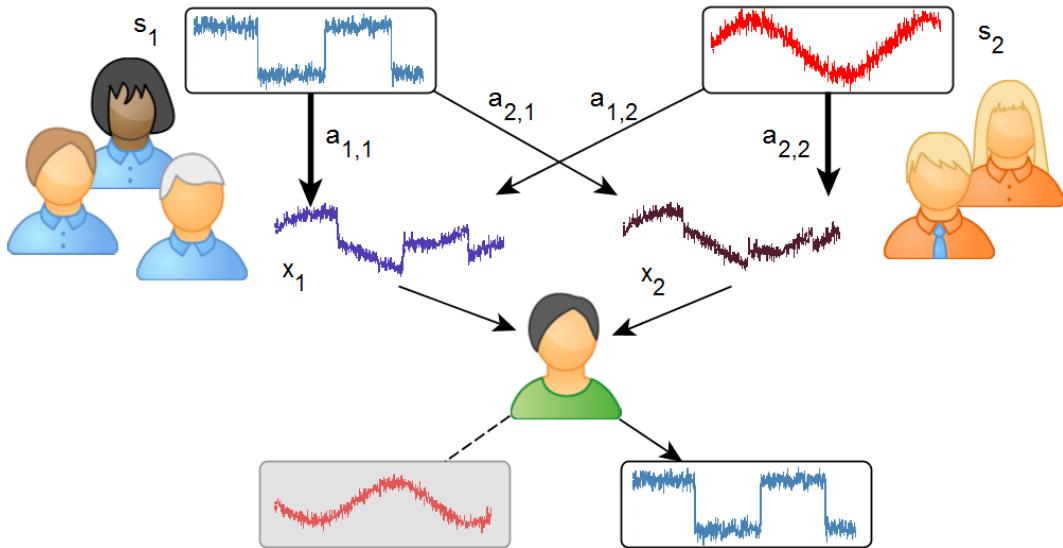


Abb. 3.7.: Zwei Gruppen (oben, blau und orange) unterhalten sich jeweils miteinander und produzieren die Originalsignale  $s$ . Die mit den Skalierungsfaktoren  $a$  vermischten Signale  $x$  kommen jeweils am linken und rechten Ohr an (mitte). Das Gehirn ist in der Lage, die Signale wieder zu trennen und das unerwünschte Signal (unten links) herauszufiltern. Das interessante Gespräch (unten rechts) bleibt erhalten und entspricht weitestgehend dem Originalsignal  $s_1$ .

mehrere Mikrofone und Anwendung der ICA kann eine gleiche Zerlegung erreicht werden. Mathematisch ließe sich diese Situation wie folgt beschreiben [HKEO01]: Gegeben seien die Mikrofonaufnahmen  $x_1(t)$  und  $x_2(t)$ . Gesucht werden die Originalsignale  $s_1(t)$  und  $s_2(t)$ , sowie die Skalierungsfaktoren  $a_{n,m}$ . Die Skalierungsfaktoren modellieren den Abstand der Mikrofone zur Signalquelle. Ein Echo im Raum wird zur Vereinfachung vernachlässigt. Gleichung 3.1 zeigt den Zusammenhang der beiden Signale und der Skalierungsfaktoren.

$$\begin{aligned} x_1(t) &= a_{1,1}s_1 + a_{1,2}s_2 \\ x_2(t) &= a_{2,1}s_1 + a_{2,2}s_2 \end{aligned} \tag{3.1}$$

Analog zum Aufteilung von Tonsignalen, wird versucht die Signale eines EEGs auf diese Art zu trennen (siehe Abb. 3.8). Die Gehirnsignale  $s_1 - s_4$  werden an den Sensoren  $x_1 - x_4$  unterschiedlich gemischt aufgenommenen und können via ICA wiederhergestellt werden. Jedoch handelt es sich hierbei um eine idealisierte Darstellung, da sich die Quellsignale (eine unbestimmte Menge von feuern den Neuronen) in der Praxis nicht genau auf die Punkte  $s_1 - s_4$  abbilden lassen.

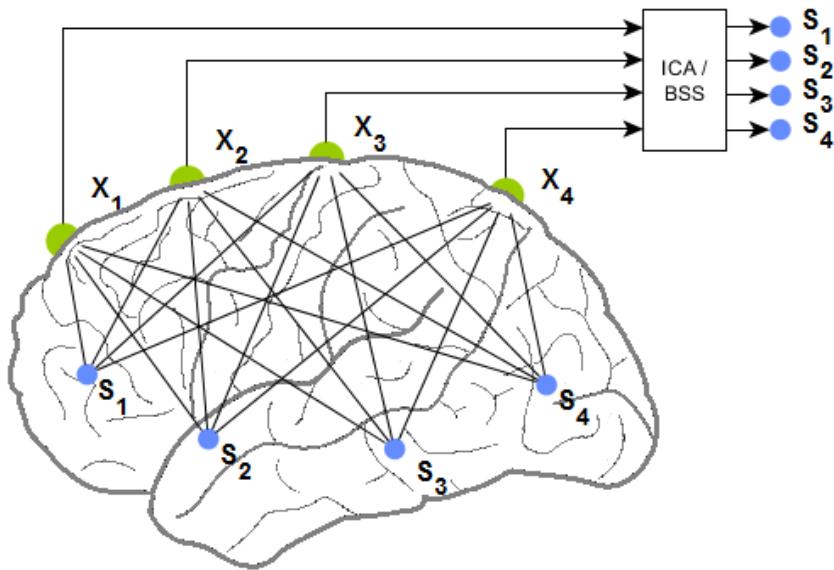


Abb. 3.8.: Die Signale  $s_1 - s_4$  werden von den Sensoren  $x_1 - x_4$  aufgenommen und wiederhergestellt (siehe Abb. angelehnt an Sanei et. al [SC08]).

Die einzelnen Originalsignale werden als Quellen (Sources,  $s$ ) oder *unabhängige Komponenten (Independent Component (IC))* und die gemischten, aufgenommen Signale als Observationen (Mixtures,  $x$ ) bezeichnet. Um die Quellsignale aus den gemischten Signalen wieder herzustellen, benötigt man mindestens die selbe Anzahl an Observationen wie Quellen (quadratischer Fall). Sind mehr Quellen als Observationen vorhanden, ist das System unterdeterminiert und nicht ohne Weiteres lösbar (es existieren jedoch auch für diesen Fall Algorithmen [KC04]).

Ziel der ICA ist die Aufteilung in möglichst unabhängige Quellsignale. Unabhängig bedeutet in diesem Kontext, sie haben keine oder möglichst wenige *gemeinsame Informationen (mutual information)*. Das heißt, man kann von einem Signalwert aus einer Quelle zu einer bestimmten Zeit, nicht auf den Wert des Signals einer anderen Quelle zum selben Zeitpunkt schließen [MO11]. Die Observationen hingegen müssen statistisch abhängig sein, ansonsten würde die ICA nicht funktionieren.

Die Problemstellung mit den enthaltenen Parametern, wird im folgenden Kapitel in ein mathematisches Modell überführt.

### 3.4.2 Mathematisches Modell

Zur mathematischen Definition, kann ein statistisch latent variables Modell genutzt werden [HKEO01]. Hierbei werden  $n$  Observationen  $x_1, \dots, x_n$  von  $n$  unabhängigen Komponenten (*independant components, IC*) aufgenommen:

$$x_j = a_{j1}s_1 + a_{j2}s_2, \dots, a_{jn}s_n, \forall j \quad (3.2)$$

Das ICA-Modell wird durch die Zufallsvariablen  $s_k$  und  $x_j$  beschrieben. Das Zeitsignal  $x(t)$  ist lediglich eine Probe der Zufallsvariable. In Vektor-Matrix-Schreibweise bezeichnen  $\vec{x} = (x_1, x_2, \dots, x_n)$  die Observationen und  $\vec{s} = (s_1, s_2, \dots, s_n)$  die Originalsignale. Die Mischmatrix  $A$  enthält alle Skalierungsfaktoren  $a_{ij}$ . Das ICA Modell kann beschrieben werden mit folgender Gleichung:

$$\begin{aligned} x &= As \\ x &= \sum_{i=1}^n a_i s_i \end{aligned} \quad (3.3)$$

Zu beachten ist, dass  $s$  und  $A$  unbekannt sind und nur mit Hilfe der Observationen  $x$  geschätzt werden können. Dazu müssen weitere Annahmen getroffen werden: die Quellsignale sind (I) statistisch unabhängig und (II) nicht Gauß-verteilt. Zur Vereinfachung wird eine quadratische Mischmatrix angenommen.

Um nun die Quellsignale zu erhalten, muss die Inverse  $W$  der Mischmatrix  $A$  gefunden werden, sodass gilt:

$$\begin{aligned} s &= Wx \\ (W &= A^{-1}) \end{aligned} \quad (3.4)$$

Abbildung 3.9 zeigt den Prozess der ICA.

Daraus folgen weitere Eigenschaften:

1. Unabhängigkeit: aus (I) folgt, dass die Quellen unabhängig sind, die Observationen aber nicht.
2. Normalität: Nach dem *zentralen Grenzwertsatz* geht die Verteilung einer Summe von unabhängigen, normierter Zufallsvariablen in Richtung Normalverteilung. Aus (II) folgt, dass die Summe der Zufallsvariablen der Gauß-Verteilung ähnlicher ist, als die Einzelsignale.
3. Komplexität: Die zeitliche Komplexität des gemischten Signals ist größer, als die des einfachsten enthaltenen Quellsignals.

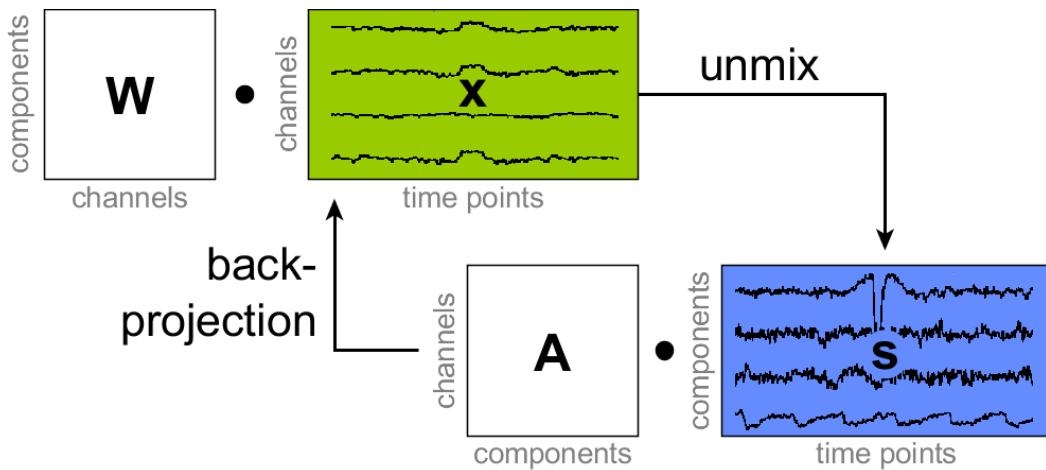


Abb. 3.9.: Die Observationen  $x$  sind das Produkt der unbekannten Quellsignale  $s$  und der Mischmatrix  $A$ . Dazu findet die ICA die Inverse von  $A$  (*Entmischungsmatrix*  $W$ ), um  $s$  zu rekonstruieren (unmix). Wird  $x$  mit veränderten ICs wieder hergestellt (bspw. ohne unerwünschte Artefakte), ist das der *backprojection* Schritt (Abbildung angelehnt an [MO11]).

Dennoch sind die Lösungen mehrdeutig, das heißt, die ICA kann die Varianz (entspricht in diesem Fall der Energie des Signals) nicht eindeutig wiederherstellen. Dies kann dazu führen, dass das wiederhergestellte Signal an der x-Achse gespiegelt ist also  $s \cdot -1$  (siehe Abb. 3.7 oben rechts und unten links). Auch die Reihenfolge der ICs ist nicht deterministisch (im Gegensatz zur PCA, bei der nach Varianz sortiert wird).

Geometrisch lässt sich die ICA als Suche nach Richtungen im Merkmalsraum mit hoher *Nicht-Gaußheit* beschreiben. Im Unterschied zur PCA müssen diese Achsen nicht orthogonal sein (siehe Abb. 3.10).

Das mathematische Modell wird im Folgenden in einen Algorithmus überführt.

### 3.4.3 Algorithmus

Um die relativ komplexe Berechnung der ICs zu vereinfachen, werden die Rohdaten einer *Vorverarbeitung* unterzogen. Hierbei werden unter anderem die Dimension des Problems und die zu schätzenden Parameter reduziert. Zuerst werden die Daten zentriert, indem von jedem Punkt der Durchschnitt  $\mathbb{E}$  abgezogen wird:

$$\begin{aligned}\bar{x} &= \mathbb{E}\{x\} \\ x_c &= x - \bar{x}\end{aligned}\tag{3.5}$$

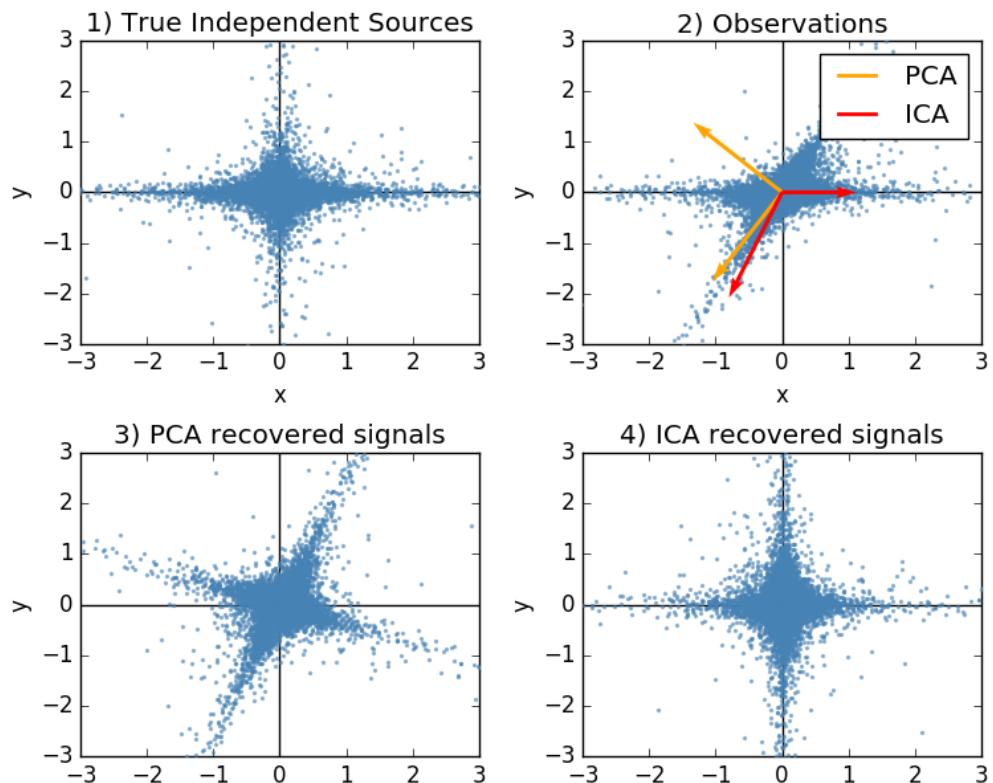


Abb. 3.10.: 1) Die Abbildung einer studentschen t-Verteilung. 2) Observationen mit einer Mischmatrix transformiert. Die gefundenen Achsen der PCA und der ICA. 3) Wiederhergestellte Signale mit PCA. Die Abbildung entspricht weitestgehend dem Original, jedoch leicht gedreht. Dieser Vorgang kann zum sog. *Whitening* eingesetzt. 4) Mit ICA wiederhergestelltes Signal. Es entspricht relativ genau dem Original [PVG<sup>+11</sup>]. .

Im zweiten Schritt wird ein sog. (*Pre-*)Whitening durchgeführt [HKEO01]. Hierbei werden die Observationen  $x$  so linear transformiert, dass die Komponenten des neuen Vektors  $\tilde{x}$  unkorreliert sind und die Kovarianzmatrix der Einheitsmatrix entspricht. Für das Whitening wird häufig die PCA eingesetzt. Sie liefert die Eigenwerte und die Eigenvektoren der Zufallsvariablen. In anderen Arbeiten wird die PCA auch *eigen-value decomposition (EVD)* [HKEO01] oder *Singular value decomposition (SVD)* [JMH<sup>+</sup>00] genannt. Abbildung 3.10 zeigt bei 3) die Daten nach durchgeführter PCA. Das Bild entspricht zwar nicht dem Original, jedoch ist die Varianz auf beiden Achsen maximal.

Ein häufig genutzter Algorithmus für die Durchführung der ICA, ist der *FastICA*. Dieser besitzt einige wünschenswerten Eigenschaften [HKEO01], denn er:

- konvergiert kubisch oder zumindest quadratisch,
- benötigt wenige einzustellende Parameter,
- lässt sich parallel und somit verteilt,
- sowie einfach und ohne großen Speicherbedarf ausführen.

Weitere Algorithmen sind *Kurtosis Maximierung* oder *Infomax*, sowie geometrische Ansätze.

Die gezeigten ICA-Algorithmen liefern Daten, die für eine Darstellung der Aktivität auf dem Kopf genutzt werden können. Diese Topomap ist Thema des folgenden Abschnitts.

### 3.4.4 Topomap

Die Positionen der Sensoren (Observationen) auf dem Kopf sind bekannt (siehe Abb. 3.2). In Kombination mit den Skalierungsfaktoren in der Mischmatrix  $A$  kann für jede Komponente (Quellsignal) eine topographische Karte (*Topo-map*, *Scalp-map*) mit den entsprechenden Stärken auf den Kopf projiziert und interpoliert werden. Dabei wird angezeigt, wie groß der Anteil des Quellsignals am jeweiligen Sensor ist. Für die Analyse des Bildes wird angenommen, dass das Quellsignal aus Sensorbereichen kommt, in denen der Betrag der Skalierungsfaktoren besonders hoch ist.

Die ICA zeigt interessante Anwendungsfälle und lässt sich in ein mathematisches Modell, sowie einen Algorithmus überführen. Eine nützliche Verwendung ist die Erstellung von Topomaps. Im folgenden Abschnitt, wird die eingesetzte Methode zur Klassifizierung der Daten vorgestellt.

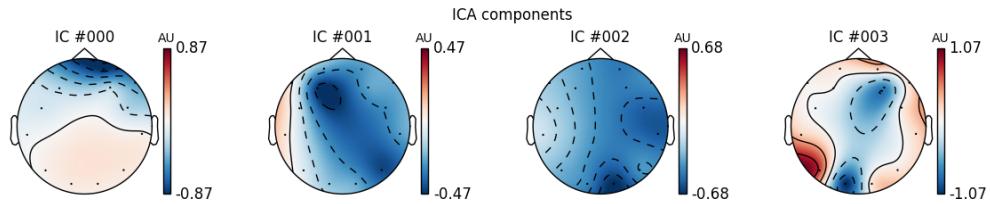


Abb. 3.11.: Topomap für vier Komponenten. Die Stärken der Skalierungsfaktoren werden auf einen Kopf projiziert (vorne die Nase, links und rechts die Ohren). Die erste Komponente (IC # 000) zeigt eine erhöhte Aktivität am rechten Auge (dunkle Stelle). Die anderen ICs können nicht so eindeutig zugeordnet werden.

### 3.5 Künstliches Neuronales Netz

Für die Entscheidung, ob ein Fahrer gerade müde oder wach ist, wird der erstellte Merkmalsvektor für jede Sequenz klassifiziert. Dafür wird ein trainierter Machine-Learning-Algorithmus eingesetzt, der in der Lage ist, auch unbekannte Datensätze in Klassen einzuteilen. In Abschnitt 2 werden bereits einige Ansätze erwähnt: KNN, auch *Multi Layer Perceptron (MLP)* genannt, SVM oder LDA. Im Vergleich von KNN und SVM finden sich unterschiedliche Forschungsarbeiten. Beide Ansätze klassifizieren in einem ähnlich guten Bereich, teils mit leichten Vorteilen beim KNN [BKDO16] und manchmal bei der SVM [SCKS11]. Aufgrund des häufigeren Einsatzes in der Literatur und der guten Bibliotheksunterstützung wurde für den Klassifikator ein KNN gewählt.

Ein KNN ist an die Arbeitsweise des menschlichen Gehirns angelehnt [Mar09]. Es basiert auf einem erweiterten McCulloch-Pitts-Neuron (Perceptron) [MP43] aus dem Jahre 1943. Abbildung 3.12 zeigt ein Perceptron, also ein KNN mit genau einem Neuron.

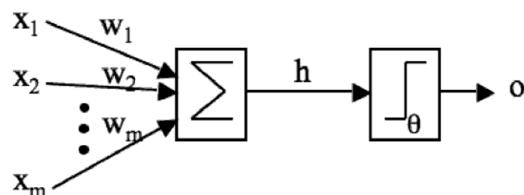


Abb. 3.12.: Schematische Darstellung eines Perceptrons. Die Merkmale  $X$  werden mit den Gewichten  $W$  multipliziert und in  $\sum$  summiert. Wenn  $h > \theta$  „feuert“ das Neuron ( $o = 1$ ). Bildquelle [Mar09].

Dieses lässt sich durch einen Eingabektor  $X = x_1, x_2 \dots x_n$ , dazugehörige Synapsengewichte  $W = w_1, w_2 \dots w_n$ , eine Übertragungsfunktion  $\sum$  und eine Schwellwertfunktion  $\theta$  beschreiben. Die Schwellwertfunktion entscheidet, ob das Neuron

„feuert“ (binäre Ausgabe) oder nicht. Dieser Aufbau kann schon einfache Aufgaben, wie bspw. ein logisches „ODER“, lösen.

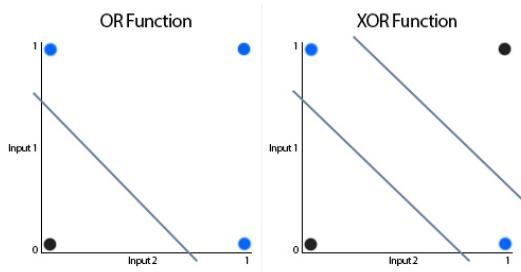


Abb. 3.13.: Das logische OR lässt sich einfach linear separieren, das logische XOR nicht. Bildquelle <http://www.theprojectspot.com/images/post-assets/ls.jpg>, 4. April 2017.

Ein logisches „XOR“ kann auf diese Weise nicht gelöst werden, da dieses Problem nicht linear separierbar ist (siehe Abb. 3.13). Für nicht-lineare Probleme müssen weitere Schichten von Neuronen (Hidden Layers) eingezogen werden. Dieses KNN wird auch Multi Layer Perceptron (MLP) genannt (siehe Abb. 3.14).

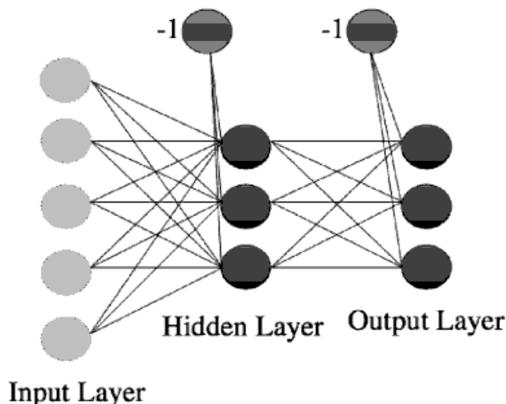


Abb. 3.14.: Darstellung eines Multi Layer Perceptron (Neuronalen Netzes mit mehreren Schichten). Bildquelle [Mar09].

Die „Intelligenz“ des Perceptrons entsteht durch die Veränderung der Gewichte und der Schwellwertfunktionen während der Trainingsphase (Lernen). Für das Training werden dem KNN eine Merkmalsmenge und die dazugehörigen Klassen eingegeben (*Überwachtes Lernen*). Bei jeder Trainingsiteration, werden die Klassifizierungsergebnisse mit den tatsächlichen Klassen in einer Fehlerfunktion verglichen und die Parameter entsprechend verändert.

Die Anzahl der Eingaben (input) und Ausgaben (output) ist durch die Länge des Merkmalsvektors und der Anzahl der Klassen festgelegt. Die Anzahl versteckter Schichten (Hidden Layer) ist durch keinen bekannten Algorithmus definierbar. Nur

wenn das Problem linear separierbar ist, sind keine Hidden Layer notwendig. Heaton [Hea08] gibt als Faustregel an, dass die Anzahl der Hidden Layer zwischen der Anzahl der Inputs und Outputs liegen sollte. Die optimal Anzahl muss jedoch für jedes Problem durch Ausprobieren gefunden werden.

Nachdem nun notwendige Grundlagen und Materialien vorgestellt wurden, folgt im nächsten die eigentliche Implementierung der Anwendung.



## 4 Erweiterung der PoSDBoS-Anwendung

Die im Masterprojekt [Pas16] entwickelte PoSDBoS-Anwendung wurde im Rahmen der Masterthesis komplett überarbeitet. Oberstes Ziel war die Verbesserung der Erkennungsrate mit besonderem Fokus auf der Verarbeitungskette.

Fachlich wurde die Verarbeitungskette um eine Artefakterkennung (Abs. 4.4) und Qualitätsprüfung (Abs. 4.5) erweitert. Auch die Vorverarbeitung (Abs. 4.3) wurde in diesem Zuge verfeinert. Dies war notwendig, nachdem die Klassifizierungsergebnisse aus dem Masterprojekt unzureichend waren (ca. 62%). Die Qualität der zu bewertenden Daten musste gesteigert werden und unbrauchbare bzw. verunreinigte Sequenzen automatisch entfernt werden.

Die Vereinfachung der Abläufe und Reduzierung der Klassen waren Änderungen auf struktureller Ebene. Die Erstellung der Objektstrukturen wurde in eine Factory-Klasse ausgelagert. Weiterhin wurden einheitliche Datenobjekte zur Kommunikation zwischen den Klassen eingesetzt. Die Übertragung zwischen den Klassen wurde zudem threadsicher und lose gekoppelt auf Queue-Basis umgesetzt. Die Package-Anordnung wurde klarer strukturiert und dabei die Kernanwendung von den Helferklassen getrennt.

Der derzeitige Entwicklungsstand, sowie technische Abläufe werden im nächsten Abschnitt näher beleuchtet. Darauffolgend werden die Datenakquise (Abs. 4.2), die Verarbeitungskette (Abs. 4.3), die Klassifizierung (Abs. 4.7) und die Ausgabe (Abs. 4.8) vorgestellt.

### 4.1 Anwendungsübersicht

Die Anwendung ist in der Programmiersprache Python geschrieben und folgt im Aufbau gängigen Mustern für Python-Projekte. Die Kernanwendung sammelt, verarbeitet und klassifiziert EEG-Signale. Sie ist in der Lage zu entscheiden, ob der Proband müde oder wach (fahrtüchtig) ist. Im Folgenden werden technische Details und interne Abläufe dargestellt.

Die Package- und Klassenstruktur (siehe Abb. 4.1) zeigt eine grobkörnige Übersicht des Systems. Das System gliedert sich in sieben logisch getrennte Packages (plus ein test-Package) ohne Unter-Packages. Jedes Package enthält zwischen zwei und zehn Klassen. Diese Struktur ermöglicht einen schnellen Überblick des Systems und macht es möglich, bestimmte Codestellen schnell zu finden. Die Hauptanwendung (App) stößt die Erstellung der Objektstruktur (Factory) an und startet die erstellten Objekte bzw. die benötigten Threads. Das Emokit-Objekt (source) liefert seine Daten an den Datensammler (collector) oder das Netzwerk (network). Die Verarbeitungskette nutzt statische Klassen des util-Packages, die App benutzt den Klassifikator (classifier), sowie den Ausgabemonitor. collector, processor und App sind lose durch zwei threadsichere Queues verbunden.

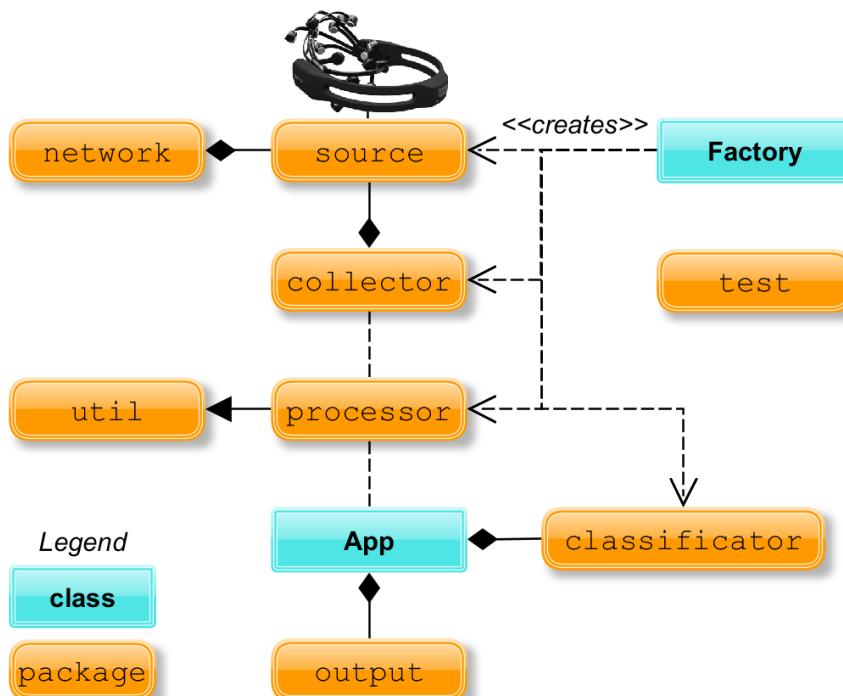


Abb. 4.1.: Zur Vereinfachung werden die Packages (orange) ohne Klassen (blau) dargestellt. Lediglich die Hauptanwendung (App) und die Klasse zur Erstellung der Objektstruktur (Factory) sind einzeln aufgeführt .

Abbildung 4.2 zeigt den Ablauf einer EEG Sequenz durch die Anwendung. Die Anwendung läuft in Minimum 4 separaten Threads, um schnellstmögliche Verarbeitung auf Mehrkernrechnern zu garantieren. Die Kommunikation mit dem EEG Headset wird durch das Emokit-Modul hergestellt. Der DataCollector sammelt die einzelnen Werte und erzeugt ein Sequenzfenster. Diese Fenster können sich überlappen und sind in ihrer Länge (in Sekunden) einstellbar. Die Verarbeitungskette übernimmt die Vorverarbeitung, Transformation und Merkmalsextraktion. Sollte dies zu lange dauern, können mehrere Ketten parallel genutzt werden. Die

App reicht die Merkmale an den *Klassifikator* und sendet das Ergebnis dann an die *Ausgabe*. Um Schwankungen und Ausreißer abzumildern, bildet die Ausgabe einen Mittelwert der Klassifizierungsergebnisse und zeigt, auf dieser Basis, den aktuellen Zustand des Fahrers an.

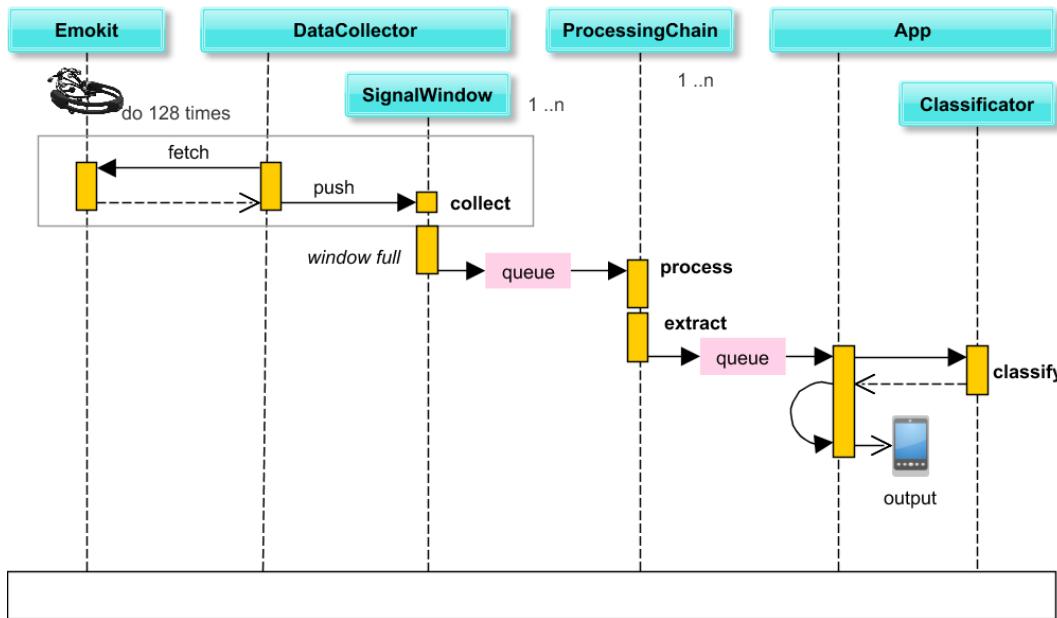


Abb. 4.2.: Die Rohsignale werden einzeln vom EEG Headset angefordert (Emokit), gesammelt (DataCollector), verarbeitet (ProcessingChain) und in der App klassifiziert (Classificator). Diese vier Threads laufen von einander unabhängig und sind durch threadsichere Queues verbunden.

Um bei der Übertragung der Sequenzen möglichst flexibel zu sein, ist es möglich, die Anwendung auch verteilt zu betreiben (siehe Abb. 4.3). Datensammlung und Verarbeitung können getrennt werden und die Daten via Netzwerk oder CAN-Interface übertragen werden.

Neben der Kernanwendung wurden zwei Helferanwendungen entwickelt. Um mehrere komplett Datensätze zu analysieren und zu plotten, wurde eine Klasse entwickelt, die verschiedene statistische Werte (Maximum, Minimum, Standardabweichung, Varianz, Signalenergie, Frequenzspektrum uvm.) ermittelt. Neben der Anzeige für jeden Probanden, wird zudem der Mittelwert über alle Datensätze errechnet. Sie wurde genutzt um geeignete Merkmale zu finden und Schwellwerte zu ermitteln. Um diese Merkmale zu validieren und weitere Besonderheiten zu finden, wurde eine grafische Oberfläche zur Analyse von Video- und EEG-Daten entwickelt. Diese erlaubt es, die Aufnahmen des Fahrers und der Fahrt, sowie der Körpersignale Bild für Bild zu vergleichen.

Nach der Gesamtübersicht des Systems, werden in den folgenden Abschnitten einzelne Stationen der Module erläutert.

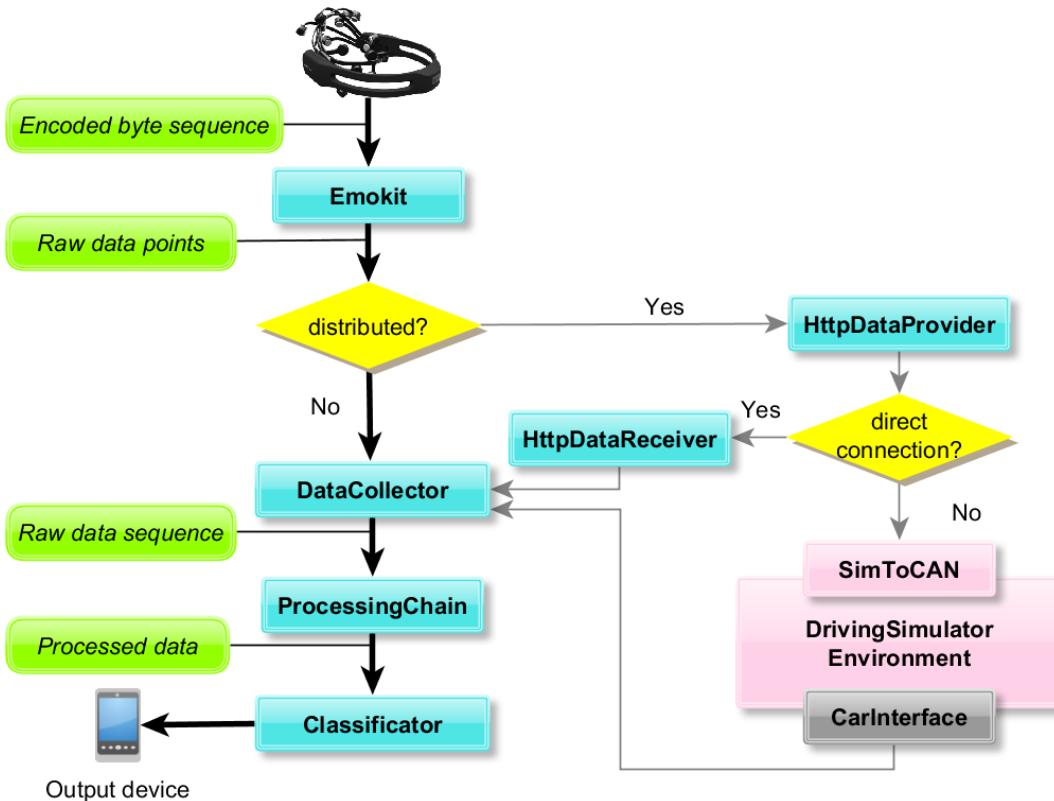


Abb. 4.3.: Der Ablauf im Normalfall (dicke Pfeile): Die Anwendung läuft komplett auf dem selben System. Die einzelnen Datenpunkte können auch per HTTP übertragen werden und dann entweder direkt empfangen oder vom Simulator auf einen CAN-Bus gelegt werden. Von dort gelangen sie in den DataCollector und werden verarbeitet.

## 4.2 Rohdatenakquise

Die Rohdaten werden decodiert und gesammelt, Abbildung 4.4 zeigt den Weg der Daten und deren Datenstrukturen.

Die Emokit Bibliothek holt die Daten des EEG-Headsets vom *Bluetooth USB Dongle*, decodiert die Bytesequenzen und liefert ca. 128 Datenstrukturen mit Signalfwert und -qualität pro Kanal in der Sekunde an den DataCollector. Dieser besitzt eine bestimmte Anzahl von Signalfenstern, welche für die Erstellung einer Sequenz zuständig sind. Die Sequenzlänge (in Sekunden) und die Anzahl der Fenster sind variabel und hängen mit der Samplingrate zusammen. Die Überlappung der Fenster ist immer gleichmäßig. Zwei Fenster mit einer Länge von einer Sekunde, ergeben eine Überlappung von einer halben Sekunde. Erhöht man die Anzahl der Fenster auf Vier, beträgt die Überlappung nur noch 250 Millisekunden. Hat ein Fenster die maximale Länge erreicht, wird die Sequenz in die `collectedQueue` gelegt. Um die Datenmenge zu reduzieren, werden in diesem Schritt nicht benötigte Kanäle aus den Sequenzen entfernt. Für die Anwendung wurde eine Fensterlänge von acht

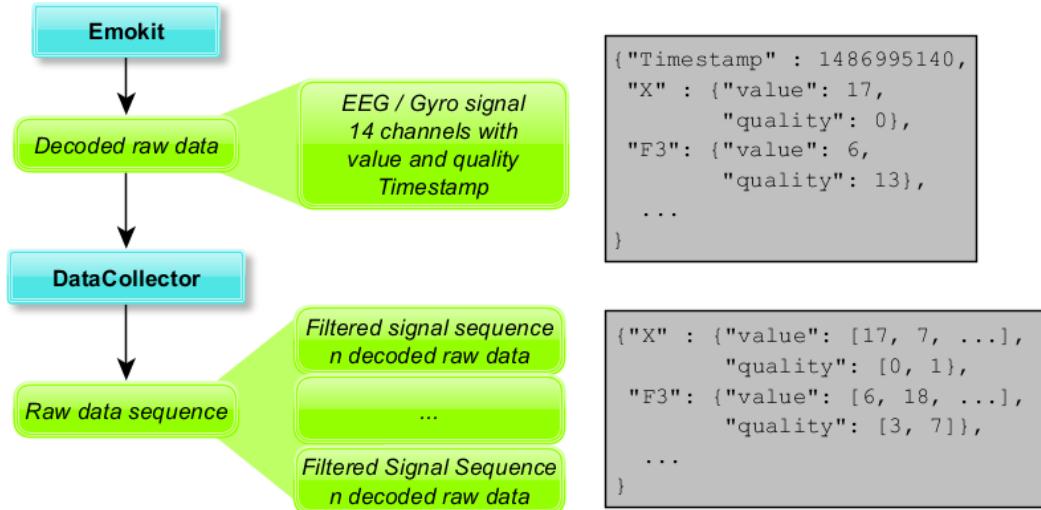


Abb. 4.4.: Die Datenstruktur des EEG-Headsets wird im DataCollector gefiltert und abhängig von der Fensterlänge aggregiert.

Sekunden und eine Überlappung von einer halben Sekunde gewählt. Dass heißt es sind 16 Sequenzfenster, mit einer Länge von 1024 Werten, im Einsatz. Diese Einstellungen ergaben sich aus Versuchen und machten die Erkennung robuster.

Nachdem die Rohdaten vom Headset zur Verfügung gestellt wurden, folgt in den nächsten Abschnitten die Verarbeitung dieser Sequenzdaten.

### 4.3 Vorverarbeitung

Um die Qualität der Daten zu steigern und die Datenmenge weiter zu verringern, ist eine Aufbereitung der Rohdaten notwendig. Gängige Verfahren der Signalverarbeitung kommen hierbei zum Einsatz. Abbildung 4.5 zeigt die gesamte Verarbeitungskette.

Um Störungen in uninteressanten Frequenzbereichen zu entfernen wird ein Bandpass-Filter eingesetzt. Angewendet auf einen Datensatz bleiben nur die gewollten Frequenzanteile im Signal erhalten. Für die Anwendung liegen die interessanten Frequenzen des EEG's zwischen 1Hz und 30Hz. Für die Berechnung wird ein linearphasiger Filter mit endlicher Impulsantwort (*finite impulse response filter, FIR-Filter*), mit Parametern, wie sie von Widmann et al. [WSM15] empfohlen werden, eingesetzt.

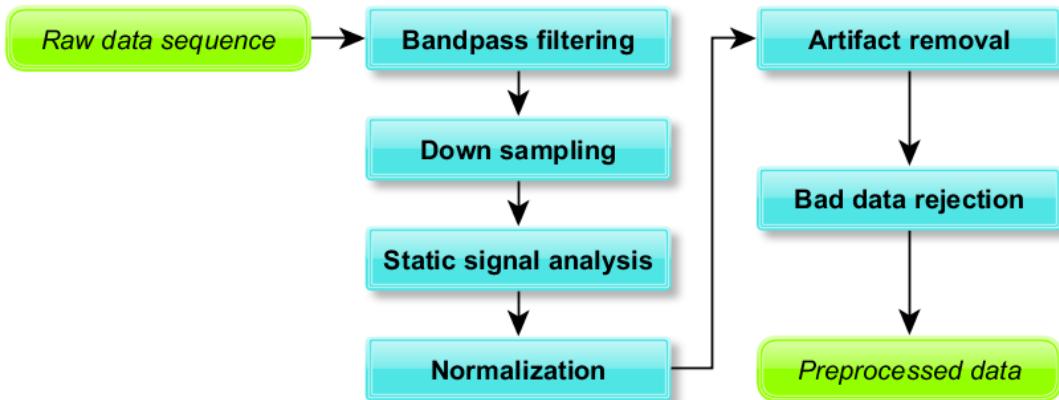


Abb. 4.5.: Die Rohdaten durchlaufen eine Verarbeitungskette, um die Qualität zu steigern und die Datenmenge zu reduzieren. Kann die Qualität der Daten nicht ausreichend verbessert werden, wird die Sequenz im letzten Schritt verworfen.

Im nächsten Schritt wird die Anzahl der Datenpunkte (Abtastrate, *Sampling-Rate*) reduziert. Diese sind vom EEG Headset vorgegeben und liegen bei ca. 128 Messungen pro Sekunde. Nach dem *Nyquist-Shannon-Abtasttheorem* hängen Abtastrate und der darstellbare Frequenzbereich zusammen, sodass die maximal darstellbare Frequenz der Hälfte der Abtastrate entspricht (für das Headset also 64Hz). Da der Frequenzbereich bereits auf 1 - 30Hz reduziert wurde, kann auch die Anzahl der Datenpunkte auf 60 reduziert werden. Da eine Datenlänge einer Zweierpotenz für die weitere Verarbeitung (FFT) Vorteile bietet, werden die Daten auf 64 Werte pro Sekunde heruntergerechnet. Mit diesem Schritt wird die Datenmenge halbiert.

Das Signal wird durch einen global ermittelten Mittelwert geteilt, um die Werte zu zentrieren. Dies ermöglicht eine Vergleichbarkeit zwischen den Probanden und ist für die spätere Schwellwertanalyse notwendig.

Das Gyroskop liefert ohne Bewegung Werte ungleich null (X: 22; Y: 21), diese werden dem Signal in der Vorverarbeitung abgezogen, um eine richtige Grundlinie zu erhalten.

Die aufbereiteten Daten werden im nächsten Schritt von weiteren Artefakten befreit.

#### 4.4 Artefaktkorrektur

Artefakterkennung und -entfernung sind wichtige Schritte bei der Verarbeitung in EEG-Signalen. Im besten Fall lassen sich Artefakte korrigieren, sodass der Datensatz trotzdem genutzt werden kann. Artefakte können durch technische (bspw. das

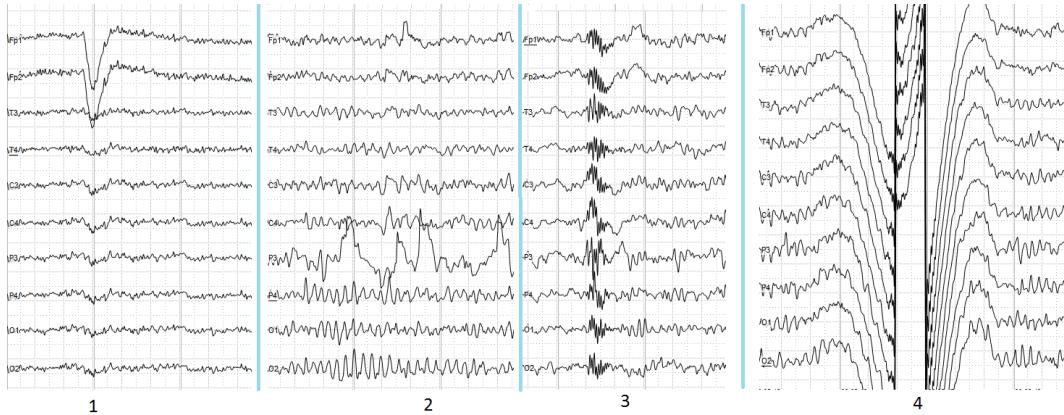


Abb. 4.6.: Verschiedene Artefakte in einem EEG-Signal: 1) EOG 2) Schlechter Sensorkontakt 3) Schlucken 4) Schlechter Kontakt der Referenzelektroden (P3 / P4).  
Bildquelle: [https://upload.wikimedia.org/wikipedia/commons/b/b1/Human\\_EEG\\_artefacts.png](https://upload.wikimedia.org/wikipedia/commons/b/b1/Human_EEG_artefacts.png), 4. April 2017.

Stromnetz) oder physiologische Faktoren ausgelöst werden. Physiologische Faktoren sind bspw. Bewegungen der Augen (EOG), des Herzens (EKG) oder anderer Muskeln (*Elektromyogramm* (EMG)). Abbildung 4.6 zeigt häufige Auswirkungen von Artefakten im EEG-Signal.

Je näher die Artefaktquelle am Gehirn sitzt, desto größer die Auswirkung. Abbildung 4.7 zeigt die Auswirkung zweier Blinzeln in den Signalen. Hierfür wurden Testdaten aufgenommen, bei der in regelmäßigen Abständen geblinzelt wurde und möglichst wenig weitere Störungen (Bewegungen) auftraten. Weiterhin ist zu sehen, dass die Auswirkungen umso größer sind, je näher die Sensoren an den Augen liegen (Sensoren AF3 und AF4). Weit entfernte Sensoren zeigen kaum Erhebungen (Sensoren O1 und O2) - siehe hierzu die Sensoraufteilung des EEGs (Abb. 3.2).

Um Artefakte zu erkennen und zu entfernen wird häufig die ICA eingesetzt (siehe Abs. 3.4). Viola et. al [VTE<sup>+</sup>09] zeigten, dass eine Erkennung für EOG Artefakte mit der ICA sehr gute Ergebnisse liefert. Ein EOG Artefakt wird bspw. durch Blinzeln erzeugt. Ein Blinzeln dauert zwischen 100 - 400 ms und ein normaler Mensch blinzelt etwa 10 - 15 mal pro Minute (also alle 4 - 6 Sekunden) [KAA03, Sch90]. Bleiben die Augen länger als drei Sekunden geschlossen wird bereits von *Sekundenschlaf* (*Microsleep*) gesprochen [ABTR05]. Ausgehend von der Annahme, dass die Signale eines Organs (Gehirn) ähnlicher (statistisch abhängiger) sind, als Signale zweier Organe (Gehirn und Auge), folgt, dass die ICA Augenartfakte (Störungen durch Blinzeln) deutlich von EEG-Signalen unterscheiden können muss [Vig97]. Abbildung 4.8 zeigt schematisch die Auswirkungen eines EOG-Artfakts.



Abb. 4.7.: Die beiden umrandeten Stellen zeigen deutliche Erhebungen und entstehen durch Blinzeln.

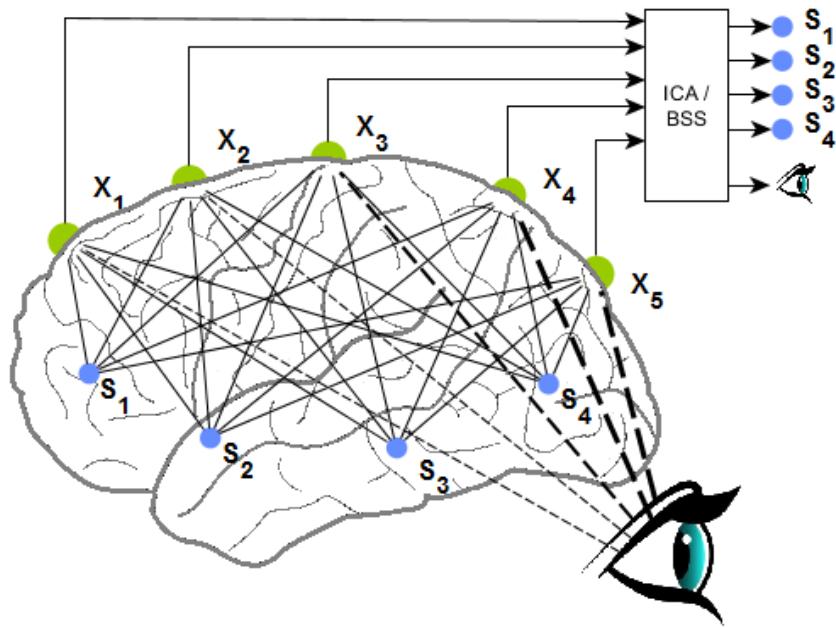


Abb. 4.8.: Das Störsignal des Auges strahlt in alle Sensoren aus und ist teilweise stärker zu erkennen, als die eigentlichen Hirnsignale. Durch ihre örtliche Nähe, werden die EOG Signale besonders deutlich in  $x_4$  und  $x_5$  in Erscheinung treten. Mit der ICA lässt sich das EOG Artefakt extrahieren und aus den Observationen entfernen (Abbildung angelehnt an [SC08]).

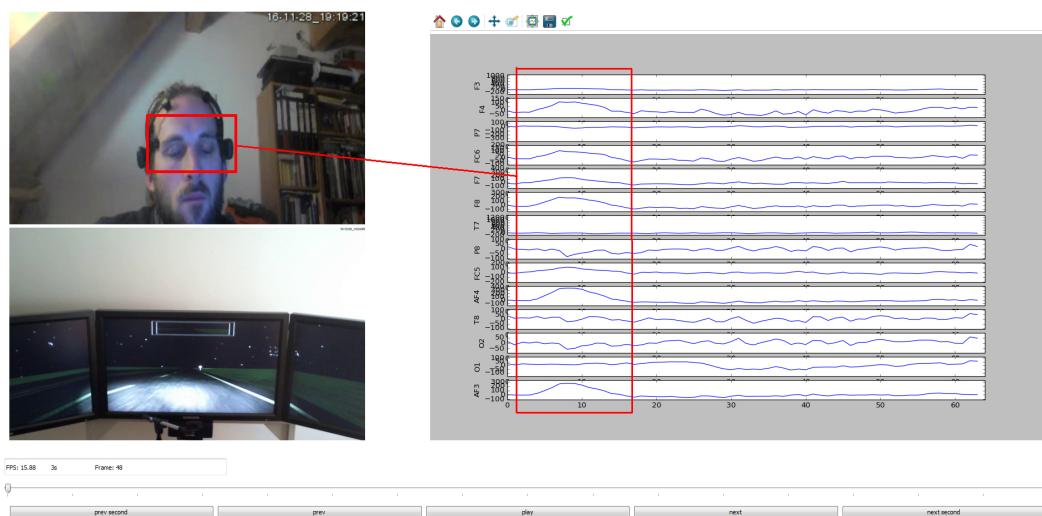


Abb. 4.9.: Das Videobild zeigt ein Blinzeln und im EEG-Signal ist eine deutliche Erhebung zu erkennen.

Um das EOG Artefakt zu finden, muss sichergestellt sein, dass das Artefakt auch in einem ICA Quellsignal auftaucht und es sich tatsächlich um ein Signal aus dem Auge handelt. Hierzu wurden das Videobild und die Topomap betrachtet. Das Videobild muss ein Blinzeln zeigen, wenn ein vermeintliches Artefakt auftaucht. Abbildung 4.9 zeigt das Videobild und EEG-Signal synchron - Blinzeln und Erhebung im Signal korrelieren.

Die Topomap (vgl. 3.4.4) muss deutliche Aktivität in der Nähe des Auges zeigen. Wie im IC # 000 zu sehen (siehe Abb. 4.10), ist hier erhöhte Aktivität in den Sensoren nahe des Augenbereichs (Sensor AF3 und AF4).

Passen beide Parameter zu einem EOG Artefakt, ist die Komponente als Störsignal erkannt worden und kann entfernt werden. Dies bedeutet, dass sie komplett gleich Null gesetzt wird und bei der Rückprojektion in keiner Observation mehr auftaucht. Da die ICA nicht deterministisch ist (die Reihenfolge der gefundenen IC's ist beliebig), müsste die Bestimmung des Artefaktkanals für jeden Datensatz manuell durchgeführt werden, was einen erheblichen Aufwand erzeugt und eine Echtzeit-anwendung unmöglich macht. Um diesen Schritt zu automatisieren wird der sog. *corrmap* Algorithmus [VTE<sup>+</sup>09] eingesetzt. Er versucht anhand eines Templates, Muster in der zu prüfenden ICA zu finden. Als Template dient das aufgenommene Testsignal, bei dem sich der EOG IC eindeutig bestimmen lässt.

Nachdem EOG-Artefakte korrigiert wurden, werden weitere Artefakte im folgenden Abschnitt ermittelt.

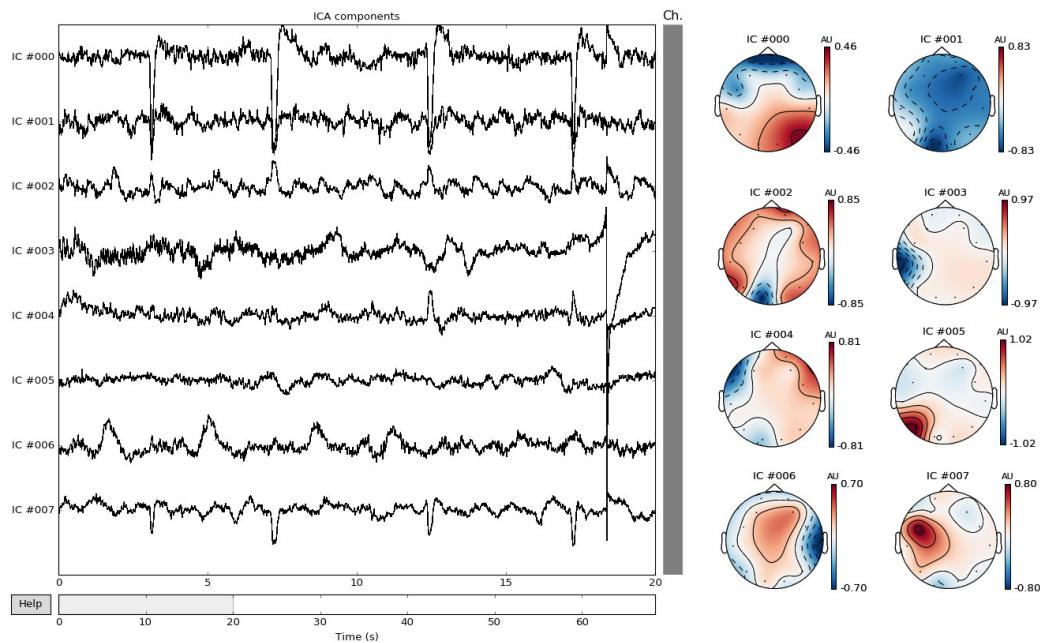


Abb. 4.10.: Die ICA Quellsignale zeigen vor allem in IC 0 regelmäßige Minima, die zum Abstand des Blinzelns passen. Mit der Analyse der Topomap zeigt sich zudem für diesen IC, dass er besonders hohe Aktivität im Bereich nahe des Auges hat. .

## 4.5 Qualitätsmetriken

Trotz Vorverarbeitung und Artefaktkorrektur sind nicht alle Sequenzen brauchbar. Einige Artefakte lassen sich nicht entfernen oder es treten sonstige zufällige Störungen bei der Aufnahme auf. Diese schlechten Sequenzen müssen erkannt werden und dürfen nicht für die Klassifizierung genutzt werden, da sie das Ergebnis verfälschen.

Einen deutlichen Zusammenhang zwischen Kopfbewegungen und starken Schwankungen im EEG-Signal lässt sich erkennen. Abbildung 4.11 zeigt die Auswirkungen einer (Kopf-) Bewegung auf die EEG-Signale (EMG Artefakt). Ein weiteres Indiz für eine Bewegung zeigt die Veränderung der Nulllinie im EKG Kanal. Im Vergleich dazu zeigt Abbildung 4.12 ein EEG-Signal ohne Bewegung. Es gibt weder einen Ausschlag im Gyroskop (X- und Y-Kanal), noch eine Verschiebung der Nulllinie im EKG. Die EEG-Signale sind einigermaßen gleichmäßig und haben keine großen Ausreißer.

Um diese Bewegungssequenzen zu finden, wird die Signalenergie (Gleichung 4.1) der Gyroskopwerte errechnet und mit einem festgelegten Schwellwert verglichen. Ist der Wert zu hoch, wird die Sequenz verworfen und nicht weiter verarbeitet.

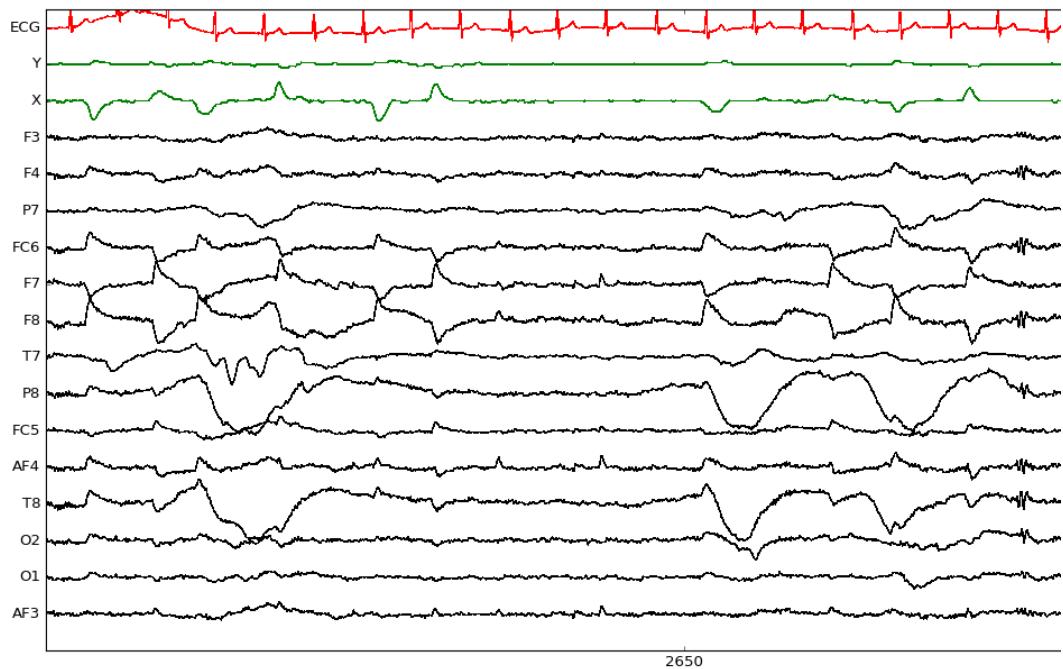


Abb. 4.11.: Eine Kopfbewegung (sichtbar im Kanal X) führt zu deutlichen Schwankungen in den EEG-Kanälen.

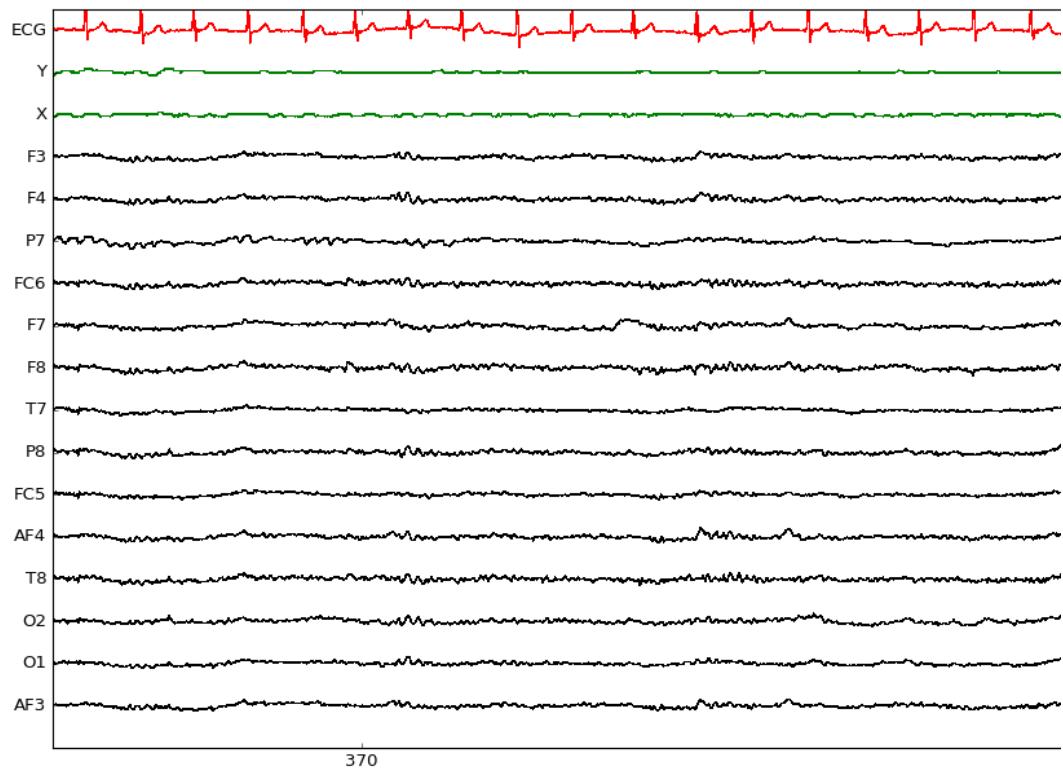


Abb. 4.12.: X- und Y-Kanal haben keinen nennenswerten Ausschlag und somit trat keine Kopfbewegung auf. Das EEG-Signal verläuft einigermaßen gleichmäßig.

$$E_s = \sum_{t=0}^n |x(t)|^2 \quad (4.1)$$

Der Versuch die Schwankungen der Kopfbewegungen, analog zu den Augenartefakten, in einem ICA Kanal zu finden, führte zu keinem sinnvollen Ergebnis. Diese Qualitätsmetrik lässt sich sehr performant realisieren und es bedarf keiner Verarbeitungsschritte der EEG-Signale.

Eine weitere Metrik ist eine Schwellwertanalyse der EEG-Signale. Aus der Verteilung aller Signale ergibt sich ein grober Wertebereich, sodass möglichst viel Signalwerte erhalten bleiben, jedoch Anomalien durch Artefakte erkannt werden. Abbildung 4.13 zeigt die Verteilung der EEG-Rohsignale für alle Probanden. Durch Versuche wurde eine statische untere und obere Grenze festgelegt. Diese liegen, für das zentrierte Signal, bei -120 und 120. Dieses Intervall deckt ungefähr 70% aller eingehenden Signalwerte ab. Die Anzahl dieser Ausreißer ( $>$  oberer Grenze und  $<$  unterer Grenze) werden pro Kanal errechnet. Werden in einem Kanal mehr als 12,5% der Werte pro Sekunde als Ausreißer deklariert, wird die komplette Sequenz verworfen. Der Prozentsatz wurde empirisch ermittelt und stellt ein angemesenes Verhältnis von Qualitätssicherung und Durchlassquote dar. Dieses Verfahren erkennt Artefakte durch schlechten Sensor- und Referenzsensorkontakt am EEG (siehe Abb. 4.6).

Aus den aufbereiteten Daten wird im nächsten Abschnitt eine Merkmalsmenge erstellt.

## 4.6 Merkmalsextraktion

Die aufbereiteten Rohdaten können nun weiter verarbeitet werden, um eine Merkmalsmenge für die Klassifizierung zu erstellen. Wichtig hierbei ist eine weitere Reduktion der Datenmenge und die Auswahl aussagekräftiger Werte, welche sich durch einen *Machine-Learning-Algorithmus* klassifizieren lassen. Frequenzbereiche erwiesen sich in vorherigen Arbeiten als gute Merkmalsträger für die Erkennung von Müdigkeit (siehe Tab. 2.2).

EEG-Signale lassen sich in sogenannte Frequenzbänder (Frequenzbereiche) zerlegen und werden mit griechischen Buchstaben benannt. Die Frequenzbänder werden von der IFCN [DE99] in folgende Bereich unterteilt:  $\delta : 0,5 - 4\text{Hz}$ ,  $\theta : 4 - 8\text{Hz}$ ,  $\alpha$

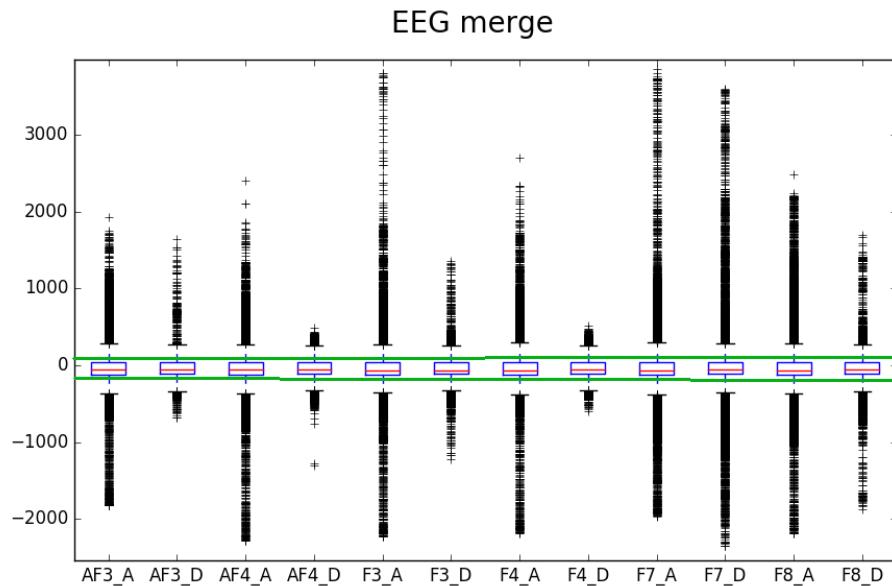


Abb. 4.13.: Boxplot der EEG Rohsignale für die Kanäle AF3, AF4, F3, F4, F7 und F8. Jeweils für die Zustände Wach (Awake: „\_A“) und Müde (Drowsy: „\_D“).

: 9 - 13Hz,  $\beta$  : 13 - 30Hz,  $\gamma$  : ab 30Hz. Erhöhte Aktivität in den Frequenzbändern weisen auf verschiedene Ereignisse oder Zustände hin [LR11, LWQ<sup>+</sup>10, GW92]. Delta-Wellen treten bei Erwachsenen häufig in der traumlosen Tiefschlafphase auf. Bei Schläfrigkeit und leichtem Schlaf, treten vermehrt Theta-Wellen auf. Alpha-Wellen werden mit leichter Entspannung und entspannter Wachheit (mit geschlossenen Augen) assoziiert. Beta-Wellen zeigen sich vor allem während der REM-Schlafphase. Bei Konzentration oder Meditation zeigt sich eine erhöhte Aktivität von Gamma-Wellen. Für Müdigkeitserkennung ist vor allem die Erkennung des Übergangs vom Wach- in den Schlafzustand interessant, also die Bereiche der Theta- und Alpha-Wellen. Mehrere Studien [HFKM76, KÅ93, Kli99, HR96] bestätigen den Zusammenhang von Müdigkeit und einer Veränderungen im Frequenzbereich der Theta- und Alpha-Wellen. In der Analyse der aufgenommenen Daten konnten diese Ergebnisse bestätigt werden. Hierbei zeigen die Kanäle „AF3“, „AF4“, „F3“, „F4“, „F7“ und „F8“ am wenigsten Störungen. Weiterhin sind die Unterschiede zwischen „Müde“ und „Wach“ besonders deutlich zu erkennen. Darauf werden für die Merkmalsextraktion die Theta-Wellen der genannten Kanäle eingesetzt und ergeben einen Merkmalsvektor der Länge 24 (4 Frequenzwerte x 6 EEG-Kanäle).

Um die benötigten Frequenzwerte zu erhalten wurde für jeden EEG-Kanal eine Fourier-Transformation [BC49] durchgeführt. Diese zerlegt das kontinuierliche Zeitsignal in sein Frequenzspektrum. Die Wavelet-Transformation [Chu92]

stellt eine Alternative zur Zerlegung dar. Beide Verfahren werden in der Literatur verwendet und es lässt sich keine eindeutige Aussage zur besseren Eignung treffen.

Der erstellte Merkmalsvektor wird im nächsten Schritt klassifiziert.

## 4.7 Klassifizierung

Die erstellten Merkmalsvektoren werden nun von einem Klassifikator in die Zustände „Müde“ und „Wach“ separiert. Tabelle 4.1 zeigt die Parameter, durch die ein *Künstliches Neuronales Netz* (KNN) beschrieben wird. Im System wird die Implementierung von *pybrain* mit einem Hidden Layer genutzt. Versuche ergaben keine Verbesserung für eine höhere Anzahl von versteckten Schichten. Die Anzahl der Inputs richtet sich nach der Länge eines Merkmalsvektors, die Anzahl der Outputs nach der Anzahl der Klassen („Müde“ und „Wach“) im binären Format. Die Gewichte und die Schwellwertfunktionen werden initial zufällig gewählt (siehe Abs. 3.5).

Für das Training werden vorab erstellte Merkmalsvektoren mit den Klassen „Wach“ und „Müde“ versehen. Diese Daten werden zufällig gemischt und im Verhältnis 2:1 in eine Trainings- und Testmenge geteilt. Die Testmenge dient nach dem erfolgreichen Abschluss des kompletten Trainings zur Überprüfung der Endergebnisse. So wird ausgeschlossen, dass das KNN zu genau auf die Trainingsmenge eingestellt wurde und nicht generalisiert hat (sog. *overfitting*). Beim Training werden wiederum 20% der Daten zum Validieren des Ergebnisses einer Iteration (*Validation Proportion*) verwendet. Es werden nun Trainingsiterationen ausgeführt und Fehlerwerte mit der Validierungsmenge berechnet. Diese sollten im Verlauf des Trainings deutlich sinken und irgendwann konvergieren. Um diesen Vorgang zu steuern, werden weitere Parameter gesetzt (siehe Tab. 4.1). Die Lernrate bildet die Lerngeschwindigkeit im Verhältnis zur Genauigkeit ab. Das Momentum (Trägheitsterm) verhindert das Steckenbleiben in lokalen Extrema. Eine ähnliche Aufgabe hat der *Continue Epochs* Parameter. Er gibt an, wie viele Iterationen durchgeführt werden, bis ein neuer bester Wert gefunden werden muss. Konvergiert das Ergebnis nicht, wird das Training nach einer bestimmten Anzahl von Iterationen abgebrochen (Max. Epochs).

---

Die Ergebnisse der Klassifizierung werden in der Ausgabe aufbereitet und dem Fahrer angezeigt.

Einstellung	Wert
Inputs	24
Outputs	1
Hidden Layers	1
Learningrate	0.005
Momentum	0.25
Max. Epochs	5000
Continue Epochs	100
Validation Proportion	0.20

Tab. 4.1.: Gesetzte Parameter des KNNs

## 4.8 Ausgabe

Der Müdigkeitsmonitor zeigt dem Fahrer an, ob er weiterhin fahrtüchtig ist oder besser eine Pause machen sollte. Dafür wurde eine Anzeige nach dem Ampelprinzip entwickelt (siehe Tab. 4.2). Die Farben Rot, Gelb und Grün sind Autofahrern bestens bekannt und unterstreichen die jeweilige Dringlichkeit des Status, ohne einen Text lesen zu müssen. Grün bzw. Rot zeigen dem Fahrer an, ob die Fahrt fortgesetzt werden kann oder ob er besser eine Pause machen sollte. Der mittlere Status (Gelb) ist für den Bereich gedacht, in dem nicht eindeutig „Müde“ oder „Wach“ klassifiziert werden kann. Es soll den Fahrer auf diesen Umstand hinweisen und ggf. seine Aufmerksamkeit erhöhen.

Status	Farbe	%	Beschreibung
Übermüdet	Rot	60-100	Die Fahrt sollte schnellstmöglich für eine Pause unterbrochen werden
Leichte Müdigkeit	Gelb	40-60	Der Fahrer sollte besonders wachsam sein und in kürze eine Pause einlegen
Wach	Grün	0-40	Die Fahrt kann ohne Pause fortgesetzt werden

Tab. 4.2.: Die angezeigten Status für den Müdigkeitsmonitor

Um die Ergebnisse zu glätten und Ausreißer nicht zu stark zu gewichten, wird die Ausgabe aus dem Mittelwert der letzten Minute gespeist. Dazu wird der Prozentsatz der Ergebnisse für die Klasse „Müde“ errechnet und gemäß Tabelle 4.2 der jeweilige Status gesetzt.

Die Ausgabe könnte zudem über ein Symbol (siehe 1.2) in der jeweiligen Farbe verdeutlicht werden. Als Anzeigeort bietet sich ein Display im direkten Sichtfeld des Fahrers an. Dies könnte nahe des Tachometers, im Navigationssystem oder im Headup-Display (in der Windschutzscheibe) sein. Ein akustisches Warnsignal wäre zudem denkbar.

In diesem Kapitel wurde PoSDBoS-System und seine Komponenten vorgestellt. Dies umfasst die Datenakquise, die Datenaufbereitung und -verarbeitung, sowie die Klassifizierung und die Ausgabe. Im folgenden Kapitel werden die Ergebnisse des Experiments und der Müdigkeitserkennung beschrieben.

## 5 Ergebnis

Die erweiterte PoSDBoS-Anwendung ist in der Lage EEG-Daten zu empfangen, zu sammeln, aufzubereiten und zu klassifizieren. Die Erkennung von Müdigkeit wurde für die erhobenen Testdaten umgesetzt und die Erkennungsrate konnte im Vergleich zum Masterprojekt [Pas16] erhöht werden.

Auf struktureller Ebene wurden Abläufe und Aufbau vereinfacht. Fachlich wurden Metriken entworfen und eingesetzt, die die Signalqualität bestimmen und teilweise verbessern können. Zum einen können EOG-Artefakte mit Hilfe der ICA korrigiert werden, zum anderen werden Sequenzen mit EMG-Artefakten nicht für die Klassifizierung eingesetzt. Oberstes Ziel dieser verbesserten Verarbeitungskette war die Steigerung der Erkennungsrate. Ein Vergleich von alter zu neuer Implementierung ist in Abschnitt 5.3 zu sehen. Zuvor werden die Ergebnisse des Experiments (Abs. 5.1) und der Anwendung (Abs. 5.2) vorgestellt.

### 5.1 Experiment

Für die Arbeit wurde das in Abschnitt 3.3 vorgestellte Experiment mit drei Probanden (P1) durchgeführt. Die Daten von fünf weiteren Probanden (P2) waren aus dem Masterprojekt vorhanden und konnten ebenfalls genutzt werden (siehe Tab. 5.1). Jeweils ein Teilnehmer aus P1 und P2 zeigte keine eindeutigen Anzeichen von Müdigkeit und wurde für die Analyse nicht berücksichtigt. Ein weiterer Fahrer wurde aus P2 entfernt, da es Probleme bei dem Sensorkontakt gab (vermutlich wegen der dichten Haare) und keine validen Daten erzeugt wurden. Somit wurden die Probanden „1“, „2“, „b“, „c“ und „e“ für die Entwicklung genutzt und in P3 zusammengefasst. Die Probanden „3“, „a“ und „b“ wurden demnach für das Training nicht berücksichtigt.

Die P1-Gruppe, ein Mann und zwei Frauen, waren allesamt zwischen 20 - 30 Jahren alt ( $\varnothing$  25) und besitzen seit 5 - 8 Jahren ( $\varnothing$  7) den Führerschein. Im Fragebogen vor dem Experiment (Anh. 7.1) gaben alle Probanden ein Aufmerksamkeitstief zwischen 14:00 und 17:00 an.

Alle acht Probanden (P1 und P2) fühlten sich nach dem Experiment subjektiv müder als zuvor. Die drei neuen Probanden gaben im Fragebogen (Anh. 7.2) zwischen ein bis zwei Müdigkeitsstufen mehr auf der KSS an. Mit fortschreitender

Proband	Alter	Geschlecht	Anzeichen	EEG	Gyro	EKG
P1						
1	20	♀	✓	✓	✓	
2	30	♀	✓	✓	✓	
3	24	♂	X	✓	✓	
P2						
a	46	♀	X	✓	X	
b	23	♂	✓	✓	X	
c	24	♂	✓	✓	X	
d	27	♂	✓	X	X	
e	28	♂	✓	✓	X	

Tab. 5.1.: Daten der Probanden aus den aktuellen Experimenten und denen aus dem Masterprojekt. Die Spalte „Anzeichen“ zeigt, ob der Proband während der Fahrt deutliche Anzeichen von Müdigkeit gezeigt hat. Die beiden letzten Spalten zeigen an, ob die Daten überhaupt und in ausreichender Qualität vorhanden waren. .

Fahrt beobachteten die Probanden an sich selbst vor allem brennende und schwere Augen, was zu häufigerem und längerem Blinzeln führte. Dies konnte in der Videoaufnahme bestätigt werden. Die Körperspannung der Fahrer lies während des Experiments ebenfalls deutlich nach. Saßen sie zu Beginn aufrecht mit aufmerksamem Blick, waren sie gegen Ende im Sitz zusammengesunken, hatten die Augen halb geschlossen und gähnten häufiger. Teilweise zeigten sich extrem gefährliche Fahrmanöver (Schlangenlinien, Abkommen von der Straße mit heftigem Gegenlenken), die im realen Straßenverkehr zu tödlichen Unfällen führen könnten. Diese Fahrfehler und andere Verhaltensauffälligkeiten konnten jedoch nur bei einem Teil der Probanden beobachtet werden. Gerade ältere Teilnehmer aus P1 zeigten deutlich weniger Auffälligkeiten als junge ungeübte Fahrer. In den Daten des Simulators konnten bei der Geschwindigkeit und Lenkbewegung kleinere Veränderungen beobachtet werden (siehe Abb. 5.1). Gegen Ende zeigte sich eine größere Varianz der Geschwindigkeit, bei den Lenkbewegungen gab es häufigere stärkere Einschläge.

Die Gyroskopdaten zeigten keine eindeutige Tendenz und zwischen den Probanden gab es deutliche Unterschiede. Über alle Probanden zeigt sich im Durchschnitt etwas mehr Bewegung am Beginn (X: 0.33, Y: 0.07) als gegen Ende (X: 0.4, Y: 0.06). Abbildung 5.2 zeigt den dazugehörigen Boxplot. Zu Beginn lässt sich lediglich eine größere Streuung in X und Y feststellen.

Beim Experiment zur Aufnahme von Testdaten mit übermüdeten Fahrern konnte bei den Probanden eine deutliche Veränderung festgestellt werden. Die Testfahrer

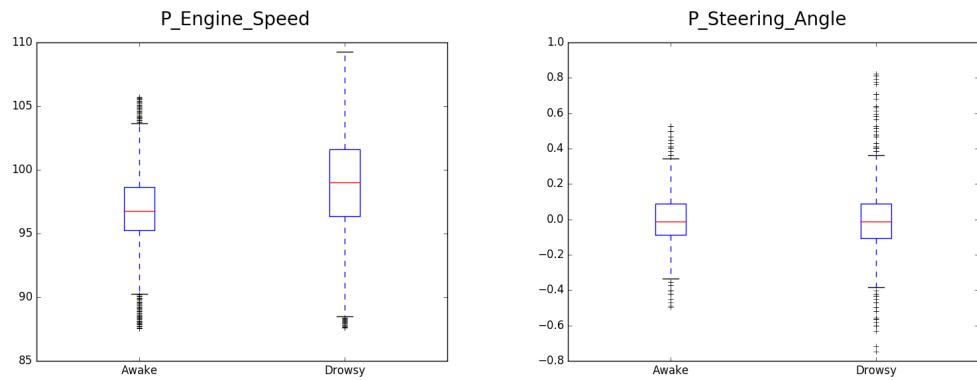


Abb. 5.1.: Boxplot für Geschwindigkeit und Lenkbewegung von Proband 3 (aus P1). „Awake“ bezeichnet Minute 3 bis 8, „Drowsy“ Minute 37 bis 42 des Experiments. Geschwindigkeit jeweils ca. 5800 und Lenkbewegung ca. 2700 Datenpunkte pro Zustand.

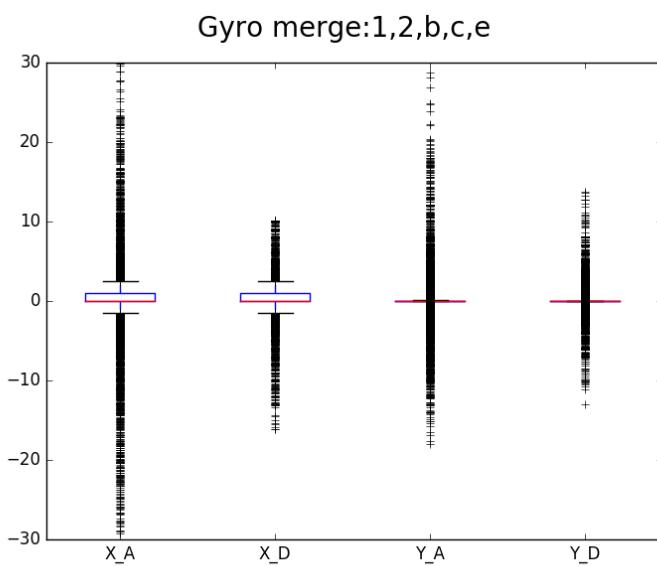


Abb. 5.2.: Boxplot für die Gyroskopwerte in X un Y Richtung, Daten von allen Probanden. „Awake“ bezeichnet den Bereich 5% bis 20% der Daten, „Drowsy“ 80% bis 95% des Experiments.

zeigten gegen Ende des Experiments eindeutige Anzeichen von Übermüdung. Die verschiedenen Müdigkeitsanzeichen innerhalb der Testgruppe können von psychologischen (bspw. Fahrerfahrung) oder physiologischen (bspw. Fitness) Merkmalen beeinflusst werden. Dies führte dazu, dass sich die Anzeichen von Person zu Person teilweise stark unterschieden und nicht alle Probanden ausreichende Anzeichen zeigten. Dennoch konnten die in Abschnitt 3.3 aufgestellten Hypothesen bestätigt werden. Hypothese 1: Die gewählten Parameter passen zu den ausgefüllten Fragebögen (Tageszeit), die Strecke wurde als sehr langweilig und ermüdend beschrieben. Die Experimentdauer kam den Probanden unangenehm lang vor. Hypothese 2: Bei den meisten Fahrern konnten Anzeichen von Müdigkeit erkannt werden. Alle Probanden fühlten sich nach dem Experiment müder als zu Beginn. Die in Abschnitt 5.2 beschriebenen Ergebnisse bestätigen Veränderungen im EEG- und EKG-Signal.

Nach den Ergebnissen des Experiments, folgen im nächsten Abschnitt die Ergebnisse der Müdigkeitserkennung.

## 5.2 Müdigkeitserkennung

Für die Erkennung von Müdigkeit wurden die Datensätze der Probanden P3 genutzt und davon jeweils 15% für die Klassen „Wach“ und „Müde“ (siehe Abb. 5.3). Bei diesem Abstand der Sequenzen, lässt sich der Unterschied der Signale am deutlichsten erkennen. Da das vorherige Experiment nur 30 Min. gedauert hatte, besteht die Merkmalsmenge zu gleichen Teilen aus neuen und alten Daten ( $2 \times 45$  Minuten und  $3 \times 30$  Minuten). Die ersten und letzten 5% der Daten wurden verworfen, um etwas Puffer zu haben. Die mittleren 60% sind nicht eindeutig und werden ebenfalls nicht für das Training genutzt. Das Ziel dieser Trennung ist die automatische Erstellung von Trainingsdaten, ohne dass eine manuelle Selektion durchgeführt werden muss (im Unterschied zum Datenset aus Abs. 5.3). Die Rohdaten durchlaufen zuvor jedoch einige Verarbeitungsschritte komplett (also nicht in einzelnen Sequenzen). Dies ist notwendig, da unter anderem die EOG-Artefakterkennung für kurze Sequenzen nicht funktioniert hat.

Der komplette Datensatz DS1 besteht aus 150.000 Signalwerten, welche zu ca. 7000 Sequenzen zusammengefasst werden. Durch die Anwendung der Qualitätsmetrik bleiben davon 4370 Sequenzen für das Training übrig. Tabelle 5.2 zeigt die Anzahl der invaliden Sequenzen aufgespalten in die Datensätze „Wach“ und



Abb. 5.3.: Das komplette Datenset eines Probanden wird in fünf Bereiche eingeteilt. Abschnitt 1, 3 und 5 werden verworfen, Abschnitt 2 wird als „Wach“ und Abschnitt 4 als „Müde“ gekennzeichnet und bilden die Trainingsmenge. .

„Müde“. Bei invaliden Sequenzen aufgrund von EEG-Artefakten gibt es deutliche Unterschiede. Im „Wach“ Zustand werden drei mal so viele Sequenzen verworfen als im „Müde“ Zustand. Etwas schwächer ist dieser Trend auch bei den Gyroskopwerten zu erkennen. Insgesamt werden bei wachen Probanden im Schnitt ca. 50% der Sequenzen verworfen, bei Müden lediglich 25%. Teilweise werden jedoch bis zu 80% der Sequenzen verworfen (vgl. Proband „1“).

Tabelle 5.2 zeigt die Klassifizierungs-Ergebnisse einzeln pro Proband und für den kompletten Datensatz DS1. Im Durchschnitt erreicht das System eine Erkennungsrate von 73% für beide Zustände. Dennoch schwanken die Ergebnisse, wie auch schon bei den invaliden Sequenzen, bei den Probanden deutlich. Proband „c“ zeigt im „Wach“ Zustand einen sehr hohen Prozentsatz (95%), wohingegen Proband „1“ mit 55% ein schlechtes Ergebnis vorweist. Jedoch zeigt dieser Proband im müden Zustand die beste Rate (85%).

Ein *Künstliches Neuronales Netz* (KNN) sollte beim Lernen generalisieren, also auch für unbekannte Daten funktionieren. Die Ergebnisse von Proband „a“ (gemittelt 70%) zeigen, dass dies der Fall ist. Genannter Proband zeigte im Experiment kaum sichtbare Anzeichen von Müdigkeit und wurde daher nicht für das Training des KNNs eingesetzt. Jedoch zeigen die Klassifizierungsergebnisse, dass trotzdem nicht sichtbare Übermüdung vorhanden war.

Tabelle 5.3 zeigt die Ergebnisse im Monitor (Abs. 4.8). Hier werden jeweils die Klassifizierungsergebnisse für eine halbe Minute (in diesem Fall 60 Sequenzen) gemittelt und in drei statt zwei Klassen überführt. Vergleicht man nun das Verhältnis von „Wach“ und „Müde“ und lässt „Leichte Müdigkeit“ außen vor, liegen die Ergebnisse bei über 90%. Im wachen Zustand ergibt sich für die Probanden „c“ und „e“ eine Erkennungsrate von 100%. Lediglich bei Proband „1“ verschlechtert sich das Ergebnis leicht (von 55% auf 51%). Nimmt man den schlechtesten Fall an und ordnet „leichte Müdigkeit“ der falschen Klasse zu, verschlechtern sich die Ergebnisse deutlich, bleiben jedoch auf dem selben Niveau wie das reine Klassifizierungsergebnis aus Tabelle 5.2.

## 1. Datensatz „Wach“

Proband	Sequenzen	Invalide			Klassifizierung		Erkennungsrate
		Gyro	EEG	„Wach“	„Müde“		
1	820	104	561	85	70		55%
2	814	17	96	492	209		70%
b	700	268	51	235	146		62%
c	606	149	62	372	23		94%
e	517	66	311	113	27		81%
<b>total</b>	<b>3457</b>	<b>604</b>	<b>1081</b>	<b>1297</b>	<b>475</b>		<b>73%</b>
a	515	64	150	192	109		64%

## 2. Datensatz „Müde“

Proband	Sequenzen	Invalide			Klassifizierung		Erkennungsrate
		Gyro	EEG	„Wach“	„Müde“		
1	820	95	244	83	456		85%
2	814	75	20	230	489		68%
b	700	251	37	116	296		72%
c	606	0	65	169	372		69%
e	517	110	20	115	272		70%
<b>total</b>	<b>3457</b>	<b>531</b>	<b>328</b>	<b>713</b>	<b>1885</b>		<b>73%</b>
a	515	59	90	89	277		76%

Tab. 5.2.: Die Ergebnisse der Datensätze „Wach“ und „Müde“. Invalide Datensätze aufgrund von Gyroskopartefakten, wurden nicht mehr auf EEG-Artefakte überprüft. Die Daten von Proband „a“ wurden nicht für das Training, sondern lediglich zum Testen eingesetzt .

## 1. Datensatz „Wach“

Proband	„Wach“	„Müde“	„leichte Müdigkeit“	Verhältnis	Erkennungsrate
1	71	68	16	51%	46%
2	556	42	103	92%	79%
b	222	35	124	86%	59%
c	395	0	0	100%	100%
e	140	0	0	100%	100%
<b>total</b>	<b>1321</b>	<b>93</b>	<b>358</b>	<b>96%</b>	<b>75%</b>
<i>a</i>	202	48	51	81%	67%

## 2. Datensatz „Müde“

Proband	„Wach“	„Müde“	„leichte Müdigkeit“	Verhältnis	Erkennungsrate
1	26	431	82	94%	80%
2	44	446	229	91%	62%
b	33	285	94	90%	69%
c	138	301	102	69%	56%
e	68	257	62	79%	66%
<b>total</b>	<b>149</b>	<b>1857</b>	<b>592</b>	<b>92%</b>	<b>72%</b>
<i>a</i>	24	256	86	91%	70%

Tab. 5.3.: Die Ergebnisse der Datensätze „Wach“ und „Müde“ im Monitor. Die Klassifizierungsergebnisse werden gemittelt und in die Zustände „Wach“, „Müde“ und „leichte Müdigkeit“ aufgeteilt (siehe 4.2). Spalte 5 zeigt das Verhältnis von „Wach“ und „Müde“ an und beachtet „leichte Müdigkeit“ nicht. Die Erkennungsrate nimmt an, dass der Zustand „leichte Müdigkeit“ falsch klassifiziert wurde (schlechtester Fall) .

Die vorgestellten Ergebnisse lassen sich ebenso im Vergleich zur vorherigen Implementierung einordnen.

### 5.3 Vergleich zur ursprünglichen Implementierung

Die in ihrem ursprünglichen Stand entwickelte PoSDBoS-Anwendung erreichte mit dem KNN (KNN2) eine Erkennungsrate von 61,5% (siehe Tab. 5.4). Der hierfür genutzte Datensatz (DS2) bestand aus 70.000 Signalwerten, die zu 1169 Sequenzen verarbeitet wurden. Die Signalwerte waren aus den Daten dreier Probanden zusammengestellt, nämlich aus den ersten („Wach“) und letzten („Müde“) 5 Minuten. Die Daten wurden manuell selektiert und bspw. grobe Ausreißer und andere Artefakte entfernt. Die Fensterlänge betrug 1 Sekunde mit 128 Signalwerten. Eine Sequenz wurde bandpass gefiltert (0.53 - 50Hz), durch eine Schwellwertanalyse von weiteren Ausreißern befreit und normalisiert. Die niedrige Erkennungsrate legt nahe, dass sich die Merkmale der Klassen „Müde“ und „Wach“ nicht deutlich genug unterscheiden oder das Signal zu viele Störungen enthielt.

	„Wach“	„Müde“	Erkennungsrate
„Wach“	226	358	61%
„Müde“	361	223	62%
Gesamt	587	581	61.5%

Tab. 5.4.: Die Ergebnisse der ursprünglichen Implementierung von PoSDBoS mit DS2 und KNN2

Im Rahmen der Arbeit, wurde der Datensatz DS2 und KNN2 genutzt, jedoch wurde er mit der neuen Verarbeitungskette aufbereitet. Tabelle 5.5 zeigt die Unterschiede der Verarbeitungsketten.

Die Ergebnisse verbesserten sich deutlich, sodass die kombinierte Erkennungsrate bei 80,5% (siehe Tab. 5.6) lag. Von den insgesamt 1168 Fenstern, wurden 209 bei der Qualitätsprüfung verworfen. Im zweiten Schritt wurde mit den neu verarbeiteten Daten ein weiteres KNN trainiert (KNN3). Dies steigerte die Erkennungsrate noch einmal auf 88%. Vor allem im Bereich der Sequenzen mit der Klasse „Müde“ wurde eine deutliche Steigerung erreicht.

Die Ergebnisse des Vergleichs und der beiden Abschnitte davor, werden im Folgenden bewertet.

Parameter	alt	neu
<b>SamplingRate</b>	128	64
<b>Fensterlänge</b>	1s	8s
<b>Bandpassfilter</b>	0.53-50Hz	1-30Hz
<b>Normalisierung</b>	✓	✓
<b>Schwellwertprüfung</b>	X	✓
<b>EOG Entfernung</b>	X	✓
<b>EMG Entfernung</b>	X	✓

Tab. 5.5.: Alte und neue Parameter bei der Verarbeitung des Datensets DS2.

KNN2			
	„Wach“	„Müde“	Erkennungsrate
„Wach“	344	70	83%
„Müde“	119	426	78%
<b>Gesamt</b>	463	496	80.5%

KNN3			
	„Wach“	„Müde“	Erkennungsrate
„Wach“	343	71	83%
„Müde“	37	508	93%
<b>Gesamt</b>	380	579	88%

Tab. 5.6.: Die Ergebnisse des ursprünglichen Datensets DS2 mit neuer Verarbeitungskette. Altes Neuronales Netz KNN2 und neu trainiertes KNN3

## 5.4 Diskussion

Die Ergebnisse zeigen, dass die Aufmerksamkeit während des Experiments abnimmt bzw. die Müdigkeit zunimmt. Dies verdeutlichen zum einen subjektive und objektive Beobachtungen von Müdigkeitsanzeichen (siehe Abs. 5.1). Zum anderen lassen sich messbare und klassifizierbare Unterschiede im EEG-Signal nachweisen (siehe Abs. 5.2). Die Klassen „Müde“ und „Wach“ werden mit einer Wahrscheinlichkeit von 73% richtig erkannt. Das in Abschnitt 1.2 definierte Ziel wurde somit erreicht. Weiterhin konnte das System Übermüdung bei Proband „a“ erkennen, obwohl es kaum sichtbare Anzeichen dafür gab. Diese Müdigkeit hätte ein fahrverhaltens- oder kamerabasiertes System unter Umständen übersehen oder zu spät erkannt.

Die Erweiterung der binären Klassifizierung im Monitor führt zu einer weiteren Stabilisierung der eindeutigen Ergebnisse und lässt eine genauere Aussage über den Zustand des Fahrers zu. Artefaktkorrektur und Qualitätsmetriken steigern die Güte der Daten und somit der Klassifizierung. Dies wird unter Anderem in Abschnitt 5.3 dargestellt, bei der für den selben Datensatz eine Steigerung von 20% bzw. 28% erreicht wurde.

Die Ergebnisse decken sich größtenteils mit denen der vorgestellten Arbeiten mit dem EEG aus Kapitel 2. Die Klassifizierungsergebnisse sind allein für sich genommen keine eindeutige Vergleichsgröße. Sie hängen direkt mit der Aufnahmeart, der Hardware und der Güte der verwendeten Daten zusammen. Einige Studien benutzten Daten von speziellen Laboren [JPO<sup>+</sup>11] oder bereiteten die Daten manuell auf [VRCP02]. Auch das Labeln der Daten wurde teilweise automatisch oder manuell [VRCP02] durchgeführt. Die Ergebnisse dieser Arbeit wurden ohne manuelles Ein greifen in den Verarbeitungs- und Labelvorgang erreicht.

Die als Merkmale eingesetzten Theta-Wellen zeigten eine niedrigere Amplitude gegen Ende des Experiments. Andere Studien [HFKM76, KÅ93, Kli99, HR96] besagen jedoch genau das Gegenteil, es bleibt zu prüfen, was diese unterschiedlichen Aussagen hervorruft.

## 5.5 Ausblick

Für weiterführende Forschungen sollte die Echtzeitfähigkeit der Anwendung ermöglicht werden. Derzeit werden Teile der Verarbeitungskette auf den kompletten Datensatz eines Experiments angewendet. So funktioniert die EOG-Artefaktkorrektur nicht für kurze Sequenzen von wenigen Sekunden. Für die gewählte Länge von 8 Sekunden (512 Zeitpunkte) wird nur bei wenigen Sequenzen ein Artefakt erkannt. Die Nutzung der EKG-Signale könnte die Erkennungsrate weiter steigern. Der genutzte EKG-Brustgurt liefert seine Daten jedoch nicht in Echtzeit. Eine weitere Quelle für Informationen könnte der extrahierte EOG-Kanal sein, dieser könnte für die Berechnung der Blinzelrate PERCLOS eingesetzt werden.

Grundsätzlich ist das Ziel weiterer Forschungen die erneute Erhöhung der Erkennungsrate. Für ein sicherheitsrelevantes System muss Übermüdung mit höchster Genauigkeit erkannt werden. Das System sollte durch weitere Experimente validiert werden. Dies beinhaltet weitere Tests im Simulator in der beschriebenen monotonen

Umgebung. Jedoch sollten auch Tests in anderen Szenarien (bspw. im Stadtverkehr) oder sogar im realen Straßenverkehr durchgeführt werden. Das System kann grundsätzlich in einem echten Fahrzeug eingesetzt werden.

Der gemittelte Müdigkeitswert könnte, abhängig von äußeren Faktoren, zu anderen Meldungen führen. Beispielsweise könnte mit fortdauernder Fahrzeit der Prozentsatz für Müdigkeitswarnungen erhöht werden, sodass der Fahrer bereits früher auf eine notwendige Pause aufmerksam gemacht wird.

Im vergangenen Kapitel wurden die Ergebnisse des Experiments, der entwickelten Anwendung und des Vergleichs mit der vorherigen Version dargestellt. Die Ergebnisse wurden eingeordnet, diskutiert und zukünftige Aufgaben formuliert. Im nächsten Kapitel wird ein Fazit gezogen.



## 6 Fazit

Die Erkennung von übermüdeten Fahrern ist eine wichtige Aufgabe und dient der Vermeidung schwerer Unfälle. Die Ergebnisse der Experimente zeigen, wie schnell es zu gefährlichen Fahrmanövern durch Übermüdung kommen kann. Die in dieser Masterthesis vorgestellte Anwendung zur Erkennung von Müdigkeit mit Körpersensoren hilft, vor diesen Situationen möglichst schnell zu warnen.

Die Ergebnisse lassen den Schluss zu, dass das entwickelte System für den beschriebenen Anwendungsfall geeignet ist. Erkennt die Anwendung Anzeichen von Müdigkeit beim Fahrer, wird dieser Umstand sofort an ihn gemeldet. Dadurch hat er genügend Zeit, einen geeigneten Ort für eine Pause zu finden. Durch die Mittelwertbildung der Klassifizierungsergebnisse kann der Zustand des Fahrers noch genauer bestimmt werden.

In den durchgeführten Experimenten zeigten die Probanden mehrheitlich äußerliche Anzeichen von Müdigkeit. Eine Veränderung der EEG-Signale konnte ebenso während des Experiments nachgewiesen werden. Diese Unterschiede zwischen Beginn und Ende des Experiments waren klassifizierbar und ermöglichen somit eine automatische Erkennung von Übermüdung. Die aufgestellten Thesen konnten validiert werden und die erzeugten Daten bildeten eine solide Grundlage für die weitere Entwicklung.

Die optimierte Verarbeitungskette führte zu einer Erhöhung der Erkennungsrate. Dies macht eine manuelle Selektion von ungeeigneten Sequenzen obsolet. Die Reduzierung der Abtastrate und die Verlängerung der zu verarbeitenden Sequenz machten das System robuster gegen Ausreißer. Die gewählten Qualitätsmetriken, sowie die Korrektur von Artefakten mittels ICA, führten zu einer Qualitätssteigerung der zu klassifizierenden Sequenzen. Die Hinzunahme des Gyroskops als Maß für Bewegung erhöht ebenso die Qualität der Daten und beschleunigt das Finden von unbrauchbaren Sequenzen. Besonders deutlich wird die Optimierung der Verarbeitungskette im Vergleich zum Masterprojekt [Pas16], welches die Basis der aktuellen Arbeit darstellt.

Der Einsatz von kostengünstiger Hardware und freier Software bedeutet nicht unbedingt schlechtere Resultate. Sie sind durchaus mit den Ergebnissen anderer Studien mit medizinischen Geräten vergleichbar. Durch die kabellose Übertragung der Daten wird der Komfort erhöht und die Handhabung vereinfacht.

Die entwickelte Anwendung zur Müdigkeitserkennung ermittelt *messbare Zeichen von Müdigkeit* (siehe Teilprobleme Abb. 1.3) und kann eine *Entscheidung über die Fahrtauglichkeit treffen*. Zusammenfassend lässt sich sagen, dass das Ziel *eine mögliche Müdigkeit des Fahrers, anhand von Veränderungen seiner Körpersignale, sicher zu erkennen*, erreicht wurde. *Die Artefaktkorrektur und die verfeinerten Qualitätsmetriken trugen maßgeblich zu der erreichten Verbesserung der Erkennungsrate bei.*

## 7 Anhang

## 7.1 Fragebogen: Vor dem Experiment



### Fragebogen: Vor dem Experiment

Proband: .....

*Die Fragen beziehen sich auf Durchschnittswerte / normale Tage.*

Wie viele Stunden schlafen Sie pro Tag?	Werktag	<input type="text"/>
	Wochenende	<input type="text"/>
Zu welcher Uhrzeit gehen Sie ins Bett?	Werktag	<input type="text"/> Uhr
Zu welcher Uhrzeit stehen Sie auf?	Werktag	<input type="text"/> Uhr

---

Zu welchen Tageszeiten sind sie besonders Leistungsfähig (aufmerksam, produktiv)?	<input type="text"/> Uhr - <input type="text"/> Uhr
	<input type="text"/> Uhr - <input type="text"/> Uhr
Zu welchen Tageszeiten haben sie ein Tief (unkonzentriert, unproduktiv)?	<input type="text"/> Uhr - <input type="text"/> Uhr
	<input type="text"/> Uhr - <input type="text"/> Uhr

---

Haben Sie einen Führerschein?	<input type="radio"/> Ja	<input type="radio"/> Nein
Wenn ja, wie lange?	<input type="text"/> Jahre	
Fahren Sie öfters längere Strecken? (> 1h)	<input type="radio"/> Ja	<input type="radio"/> Nein
Wenn ja, wie oft (pro Tag, Woche, Monat)?	<input type="text"/>	

---

Haben Sie Erfahrungen mit Müdigkeits- erkennung in einem Fahrzeug gemacht?	<input type="text"/>
---	----------------------

Würden Sie sich bei einem Neuwagen ein System zur Müdigkeitserkennung mitbestellen?	<input type="radio"/> Ja	<input type="radio"/> Nein
--	--------------------------	----------------------------



## 7.2 Fragebogen: Nach dem Experiment



### Fragebogen: Nach dem Experiment

Datum / Uhrzeit: .....

Proband: .....

Wie viele Stunden haben Sie in den letzten 24h geschlafen?  < 6  6-8  > 8

Beurteilen Sie die Qualität ihres Schlafes  Gut     Schlecht

Wie Müde fühlten Sie **vor** dem Experiment?  
(Skala 1 - 9)

Wie Müde fühlten Sie **nach** dem Experiment?  
(Skala 1 - 9)

1 Extrem wach (aufmerksam)

6 Ein paar Anzeichen von Müdigkeit

2 Sehr wach

7 Müde, aber **keine** Mühe wach zu bleiben

3 wach

8 Müde, aber **etwas** Mühe wach zu bleiben

4 Ein wenig wach

9 Sehr Müde, **große** Mühe wach zu bleiben,  
gegen Müdigkeit ankämpfend

5 Weder wach, noch müde

Konnten Sie während des Experiments eine Veränderung Ihrer Aufmerksamkeit / Müdigkeit erkennen? (Wenn möglich mit ungefährem Zeitpunkt)

Ja  Nein

Welche Anzeichen von Müdigkeit kennen Sie?

Konnten Sie einige davon bei sich während der Fahrt beobachten? Wenn ja, welche?

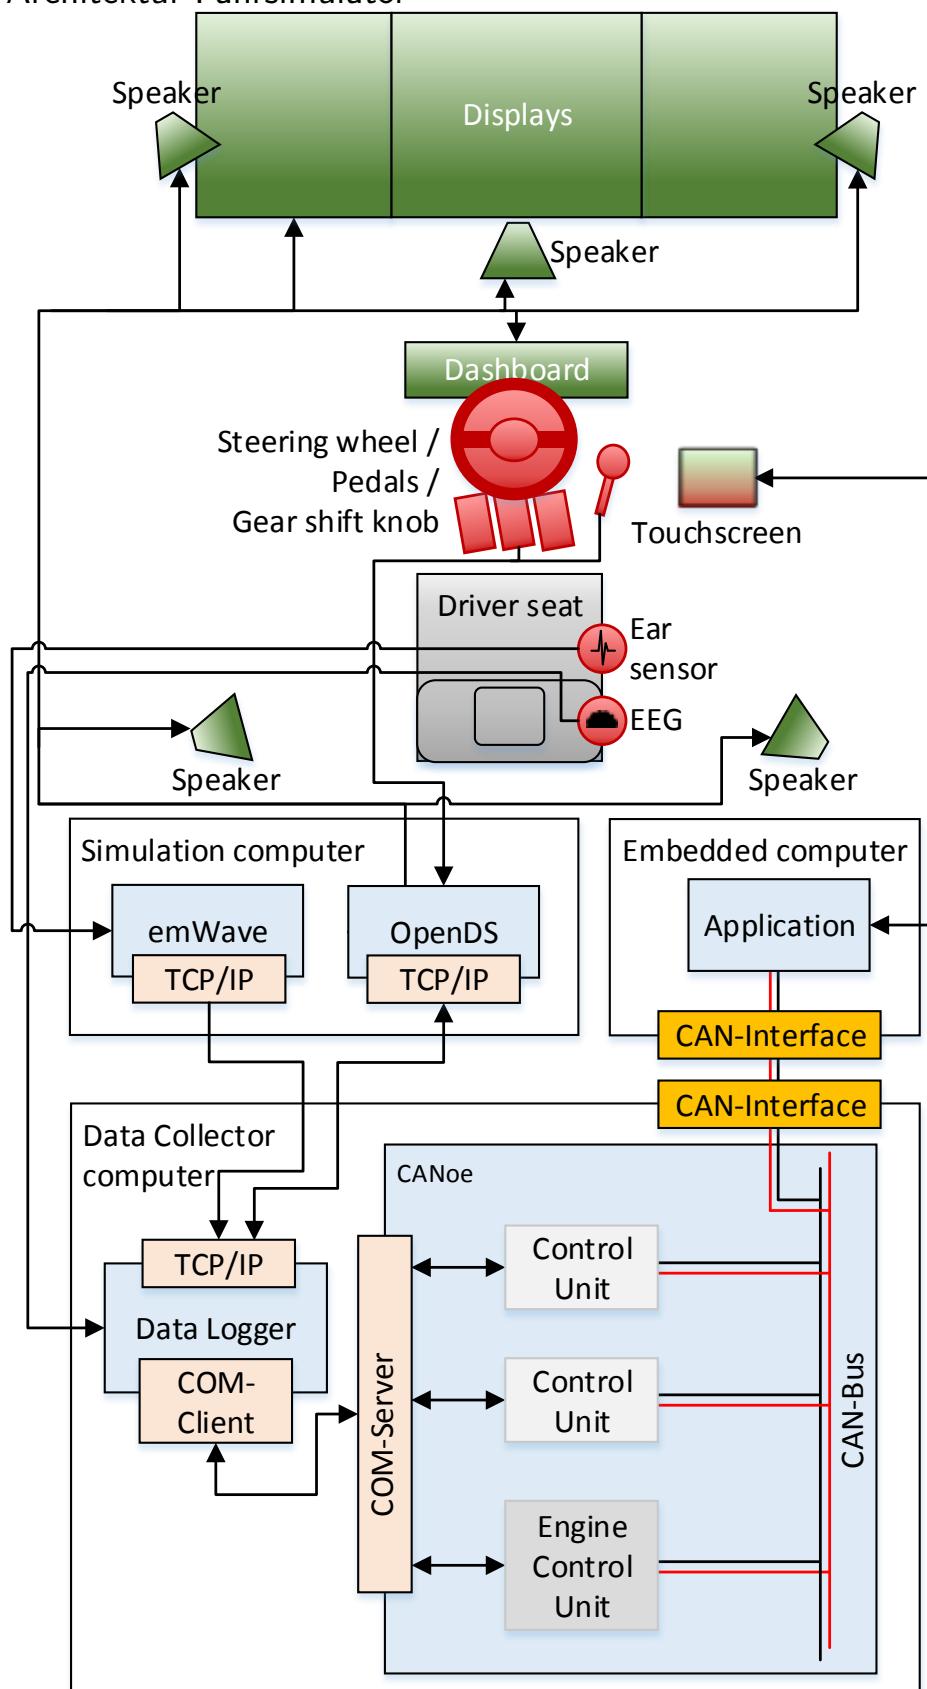
Ja  Nein

Kannten Sie den Fahrsimulator schon vor dem Experiment (schon einmal gefahren)?

Ja  Nein



### 7.3 Architektur Fahrsimulator



## 8 Literaturverzeichnis

- [ABTR05] P. Amit, L. Boyle, J. Tippin, and M. Rizzo. Variability of driving performance during microsleeps. In *Proceedings of the Third International Driving Symposium on Human Factors in Driver Assessment, Training and Vehicle Design*, pages 433–440, 2005.
- [Ake00] T Akerstedt. Consensus Statement: Fatigue and accidents in transport operations. *Journal of Sleep Research*, 9(4):395–395, 2000.
- [BB09] M. M. Bundele and R. Banerjee. Detection of Fatigue of Vehicular Driver Using Skin Conductance and Oximetry Pulse: A Neural Network Approach. In *Proceedings of the 11th International Conference on Information Integration and Web-based Applications & Services*, iiWAS '09, pages 739–744, New York, NY, USA, 2009. ACM.
- [BBM<sup>+</sup>12] R. E. Brown, R. Basheer, J. T. McKenna, R. E. Strecker, and R. W. McCarley. Control of sleep and wakefulness. *Physiological reviews*, 92(3):1087–1187, 2012.
- [BC49] S. Bochner and K. Chandrasekharan. *Fourier Transforms*. Princeton University Press, 1949.
- [Ben16] Mercedes Benz. Attention assist, 2016. [http://m.mercedes-benz.de/de\\_DE/attention-assist/detail.html](http://m.mercedes-benz.de/de_DE/attention-assist/detail.html), Zugriff: 2017-04-03.
- [BKDO16] I. Belakhdar, W. Kaaniche, R. Djmel, and B. Ouni. A comparison between ann and svm classifier for drowsiness detection based on single eeg channel. In *2016 2nd International Conference on Advanced Technologies for Signal and Image Processing (AT SIP)*, pages 443–446, March 2016.
- [BMM<sup>+</sup>13] N.A. Badcock, P. Mousikou, Y. Mahajan, P. de Lissaand J. Thie, and G. McArthur. Validation of the Emotiv EPOC® EEG gaming system for measuring research quality auditory ERPs, 2013.

- [BNS<sup>+</sup>06] L. M. Bergasa, J. Nuevo, M. A. Sotelo, R. Barea, and M.E. Lopez. Real-time system for monitoring driver vigilance. *Intelligent Transportation Systems, IEEE Transactions on*, 7(1):63–77, March 2006.
- [Bra97] Andrew P. Bradley. The use of the area under the roc curve in the evaluation of machine learning algorithms. *Pattern Recogn.*, 30(7):1145–1159, July 1997.
- [BTS16] D. S. Benitez, S. Toscano, and A. Silva. On the use of the emotiv epoc neuroheadset as a low cost alternative for eeg signal acquisition. In *2016 IEEE Colombian Conference on Communications and Computing (COLCOM)*, pages 1–6, April 2016.
- [Bun15a] Stat. Bundesamt. Unfallbilanz 2015: Mehr Unfälle und mehr Verkehrstote. [https://www.destatis.de/DE/PresseService/Presse/Pressekonferenzen/2016/Unfallentwicklung\\_2015/pm\\_unfallentwicklung\\_PDF.html](https://www.destatis.de/DE/PresseService/Presse/Pressekonferenzen/2016/Unfallentwicklung_2015/pm_unfallentwicklung_PDF.html), 2015. Zugriff: 2017-04-03.
- [Bun15b] Stat. Bundesamt. Verkehrsunfälle - Zeitreihen 2015. <https://www.destatis.de/DE/Publikationen/Thematisch/TransportVerkehr/Verkehrsunfaelle/VerkehrsunfaelleZeitreihen.html>, 2015. Zugriff: 2017-04-03.
- [Che53] E. C. Cherry. Some Experiments on the Recognition of Speech, with One and with Two Ears. *The Journal of the Acoustical Society of America*, 25(5):975–979, 1953.
- [Chu92] C. K. Chui. *An Introduction to Wavelets*. Academic Press Professional, Inc., San Diego, CA, USA, 1992.
- [DE99] G. Deuschl and A. Eisen. IFCN guidelines for topographic and frequency analysis of EEGs and EPs. 1999.
- [Dun89] G. H. Dunteman. *Principal components analysis*. Number 69. Sage, 1989.
- [EJO05] J. Engstrom, E. Johansson, and J. Ostlund. Effects of visual and cognitive load in real and simulated motorway driving. *Transportation Research Part F: Traffic Psychology and Behaviour*, 8(2):97–120, March 2005.

- [Eka15] H. Ekanayake. P300 and Emotiv EPOC: Does Emotiv EPOC capture real EEG? <http://neurofeedback.visaduma.info/P300OnEmotiv.pdf>, 2015. Zugriff: 2017-04-03.
- [e.V16] ADAC e.V. Müdigkeit im Straßenverkehr. [https://www.adac.de/\\_mmm/pdf/vm\\_muedigkeit\\_im\\_strassenverkehr\\_flyer\\_48789.pdf](https://www.adac.de/_mmm/pdf/vm_muedigkeit_im_strassenverkehr_flyer_48789.pdf), 2016. Zugriff: 2017-04-03.
- [Eve08] C. Evers. Unterschätzte Risikofaktoren Übermüdung und Ablenkung als Ursachen für schwere Lkw-Unfälle. [http://www.dvr.de/presse/seminare/904\\_20.htm](http://www.dvr.de/presse/seminare/904_20.htm), 2008. Zugriff: 2017-04-03.
- [GLL<sup>+</sup>13] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, R. Goj, M. Jas, T. Brooks, L. Parkkonen, et al. MEG and EEG data analysis with MNE-Python. *Frontiers in neuroscience*, 7:267, 2013.
- [Gmb12] Robert Bosch GmbH. Bosch Driver Drowsiness Detection, 2012. Available at <http://www.bosch-presse.de/pressportal/en/bosch-driver-drowsiness-detection-41616.html>, Zugriff: 2017-04-03.
- [Gmb15] Robert Bosch GmbH. Notbremsysteme und Spurassistenten sind auf dem Vormarsch, 2015. Available at <http://www.bosch-presse.de/pressportal/de/notbremsysteme-und-spurassistenten-sind-auf-dem-vormarsch-43164.html>, Zugriff: 2017-04-03.
- [GW92] A. Gundel and G. F. Wilson. Topographical changes in the ongoing EEG related to the difficulty of mental tasks. *Brain Topography*, 5(1):17–25, 1992.
- [HCTC96] R. S. Huang, K. J. Chung, L.-L. Tsai, and O. T. C. Chen. Eeg pattern recognition-arousal states detection and classification. In *Neural Networks, 1996., IEEE International Conference on*, volume 2, pages 641–646 vol.2, Jun 1996.
- [Hea08] Jeff Heaton. *Introduction to neural networks with Java*. Heaton Research, Inc., 2008.

- [Hel13] Comparison of driving simulator performance with real driving after alcohol intake: A randomised, single blind, placebo-controlled, cross-over trial. *Accident Analysis & Prevention*, 53:9 – 16, 2013.
- [HFKM76] M. Horvath, E. Frantik, K. Kopřiva, and J. Meissner. EEG theta activity increase coinciding with performance decrement in a monotonous task. *Activitas nervosa superior*, 1976.
- [HKEO01] A. Hyvarinen, J. Karhunen, and Erkki E. Oja. *Independent component analysis*. Adaptive and learning systems for signal processing, communications, and control. John Wiley, New York, Chichester, Weinheim, 2001.
- [HR96] J. Horne, , and L. Reyner. Counteracting driver sleepiness: effects of napping, caffeine, and placebo. *Psychophysiology*, 33(3):306–309, 1996.
- [HR99] J. Horne and L. Reyner. Vehicle accidents related to sleep: a review. *Occupational and Environmental Medicine*, pages 289–294, May 1999.
- [Ins11] Texas Instruments. Improving Common-Mode Rejection Using the Right-Leg Drive Amplifier. <http://www.ti.com/lit/an/sbaa188/sbaa188.pdf>, 2011. Zugriff: 2017-04-03.
- [Jas58] H. H. Jasper. The ten twenty electrode system of the international federation. *Electroencephalography and Clinical Neurophysiology*, 10:371–375, 1958.
- [JH91] C. Jutten and J. Herault. Blind Separation of Sources, Part 1: An Adaptive Algorithm Based on Neuromimetic Architecture. *Signal Process.*, 24(1):1–10, August 1991.
- [JMH<sup>+</sup>00] T.-P. Jung, S. Makeig, C. Humphries, T.-W. Lee, M. J. McKeown, V. Iragui, and T. J. Sejnowski. Removing electroencephalographic artifacts by blind source separation. *Psychophysiology*, 37(02):163–178, 2000.
- [Joh98] M Johns. Rethinking the assessment of sleepiness. *Sleep medicine reviews*, 2(1):3—15, February 1998.

- [JPO<sup>+</sup>11] R. R. Johnson, D. P. Popovic, R. E. Olmstead, M. Stikic, D. J. Levendowski, and C. Berka. Drowsiness/alertness algorithm development and validation using synchronized EEG and cognitive performance to individualize a generalized model. *Biological psychology*, 87(2):241–250, May 2011.
- [KÅ93] G. Kecklund and T. Åkerstedt. Sleepiness in long distance truck driving: an ambulatory EEG study of night driving. *Ergonomics*, 36(9):1007–1017, 1993.
- [KAA03] P.L. Kaufman, A. Alm, and F. H. Adler. *Adler's Physiology of the Eye: Clinical Application*. Adler's Physiology of the Eye. Mosby, 2003.
- [KBRD00] K. B. Khalifa, M. H. Bedoui, R. Raytchev, and M. Dogui. A portable device for alertness detection. In *Microtechnologies in Medicine and Biology, 1st Annual International Conference On. 2000*, pages 584–586, 2000.
- [KC04] S. Kim and Y. Chang. *Underdetermined Independent Component Analysis by Data Generation*, pages 445–452. Springer Berlin Heidelberg, Berlin, Heidelberg, 2004.
- [KHH<sup>+</sup>16] M. Klüver, C. Herrigel, C. Heinrich, H.-P. Schöner, and H. Hecht. The behavioral validity of dual-task driving performance in fixed and moving base driving simulators. *Transportation research part F: traffic psychology and behaviour*, 37:78–96, 2016.
- [KKLD11] R. N. Khushaba, S. Kodagoda, S. Lal, and G. Dissanayake. Driver Drowsiness Classification Using Fuzzy Wavelet-Packet-Based Feature-Extraction Algorithm. *Biomedical Engineering, IEEE Transactions on*, 58(1):121–131, Jan 2011.
- [Kli99] Wolfgang Klimesch. EEG alpha and theta oscillations reflect cognitive and memory performance: a review and analysis. *Brain Research Reviews*, 29(2–3):169 – 195, 1999.
- [KTÅ<sup>+</sup>06] K. Kaida, M. Takahashi, T. Åkerstedt, A. Nakata, Y. Otsuka, T. Haratani, and K. Fukasawa. Validation of the Karolinska sleepiness scale against performance and EEG variables. *Clinical Neurophysiology*, 117(7):1574–1581, 2006.

- [KTvdH96] N. Kaptein, J. Theeuwes, and R. van der Horst. Driving simulator validity: Some considerations. pages 30–36, 1996.
- [LHL09] C. Liu, S. Hosking, and M. Lenné. Predicting driver drowsiness using vehicle measures: Recent insights and future challenges. *Journal of safety research*, 40(4):239–245, 2009.
- [LKC<sup>+</sup>06] C.-T. Lin, L.-Wei Ko, I-F. Chung, T.-Y. Huang, Y.-C. Chen, T.-P. Jung, and S.-F. Liang. Adaptive EEG-based alertness estimation system by using ICA-based fuzzy neural networks. *IEEE Transactions on Circuits and Systems I: Regular Papers*, 53(11):2469–2476, 2006.
- [LLC16] B. L. Lee, B. G. Lee, and W. Y. Chung. Standalone wearable driver drowsiness detection system in a smartwatch. *IEEE Sensors Journal*, 16(13):5444–5451, July 2016.
- [LR11] S. Lei and M. Roetting. Influence of Task Combination on EEG Spectrum Modulation for Driver Workload Estimation. *Human Factors*, 53(2):168–179, 2011.
- [LWL<sup>+</sup>05] C.-T. Lin, R.-C. Wu, S.-F. Liang, W.-H. Chao, Y.-J. Chen, and T.-P. Jung. EEG-based drowsiness estimation for safety driving using independent component analysis. *IEEE Trans. Circuits Syst. I, Reg. Papers*, pages 2726–2738, 2005.
- [LWQ<sup>+</sup>10] J.-Y. Lv, T. Wang, J. Qiu, S.-H. Feng, S. Tu, and D.-T. Wei. The electrophysiological effect of working memory load on involuntary attention in an auditory–visual distraction paradigm: an ERP study. *Experimental Brain Research*, 205(1):81–86, 2010.
- [MAGGAR16] L. M. Soria Morillo, J. A. Alvarez-Garcia, L. Gonzalez-Abril, and J. A. Ortega Ramírez. Discrete classification technique applied to TV advertisements liking recognition system based on low-cost EEG headsets. *BioMedical Engineering OnLine*, 15(1):75, 2016.
- [Mar09] S. Marsland. *Machine learning : an algorithmic perspective*. Chapman & Hall/CRC machine learning & pattern recognition series. CRC Press, Boca Raton, 2009. A Chapman & Hall book.

- [MB09] J. F. May and C. L. Baldwin. Driver fatigue: The importance of identifying causal factors of fatigue when considering detection and countermeasure technologies. *Transportation Research: Part F*, 2009.
- [MKB<sup>+</sup>06] H. J. Moller, L. Kayumov, E. L. Bulmash, J. Nhan, and C. M. Shapiro. Simulator performance, microsleep episodes, and subjective sleepiness: normative data using convergent methodologies to assess driver drowsiness. *Journal of psychosomatic research*, 61(3):335–342, 2006.
- [MO11] S. Makeig and J. Onton. ERP features and EEG dynamics: an ICA perspective. *Oxford handbook of event-related potential components*, 2011.
- [MP43] W. S. McCulloch and W. Pitts. A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*, 5(4):115–133, 1943.
- [Nat16] National Sleep Foundation USA. Warning Signs. <https://sleepfoundation.org/sleep-topics/drowsy-driving>, 2016. Zugriff: 2017-04-03.
- [oDFS98] NCSDR/NHTSA Expert Panel on Driver Fatigue and Sleepiness. *Drowsy Driving and Automobile Crashes*. National Highway Traffic Safety Administration, 1998.
- [Pas16] P. Pasler. PoSDBoS - Portable System to Detect Driver Drowsiness with Body Sensors. <https://github.com/ppasler/current-adas/raw/85f97dff4df22215c0cb15648de4c14d9a4cb0f0/project/paper/paper.pdf>, 2016. Zugriff: 2017-04-03.
- [Pea01] K. Pearson. On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11):559–572, 1901.
- [POH09] H. Park, S. Oh, and M. Hahn. Drowsy Driving Detection Based on Human Pulse Wave by Photoplethysmography Signal Processing. In *Proceedings of the 3rd International Universal Communication Symposium*, IUCS '09, pages 89–92, New York, NY, USA, 2009. ACM.

- [PVG<sup>+</sup>11] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [RGB<sup>+</sup>09] E. Rogado, J.L. Garcia, R. Barea, L. M. Bergasa, and E. Lopez. Driver fatigue detection system. In *Robotics and Biomimetics, 2008. ROBIO 2008. IEEE International Conference on*, pages 1105–1110, Feb 2009.
- [SC08] S. Sanei and J.A. Chambers. *EEG Signal Processing*. Wiley, 2008.
- [Sch90] H. R. Schiffman. *Sensation and perception: An integrated approach*. John Wiley & Sons, 1990.
- [SCKS11] R. Singla, B. Chambayil, A. Khosla, and J. Santosh. Comparison of SVM and ANN for classification of eye events in EEG. *Journal of Biomedical Science and Engineering*, (4):62–69, 2011.
- [SH16] N. N. Sari and Y. P. Huang. A two-stage intelligent model to extract features from PPG for drowsiness detection. In *2016 International Conference on System Science and Engineering (ICSSE)*, pages 1–2, July 2016.
- [SSK<sup>+</sup>11] M. Simon, E. A. Schmidt, W. E. Kincses, M. Fritzsche, A. Bruns, C. Aufmuth, M. Bogdan, W. Rosenstiel, and M. Schrauf. EEG alpha spindle measures as indicators of driver fatigue under real traffic conditions. *Clinical Neurophysiology*, 122(6):1168–1178, 2011.
- [SSTA16] R. K. Singh, A. Sarkar, R. K. Thakur, and C. S. Anoop. A real-time heart-rate monitor using non-contact electrocardiogram for automotive drivers. In *2016 IEEE First International Conference on Control, Measurement and Instrumentation (CMI)*, pages 484–488, Jan 2016.
- [Ste08] Stedman. *Stedman's Medical Dictionary*. Lippincott Williams & Wilkins, 2008.
- [Sub05] A. Subasi. Automatic Recognition of Alertness Level from EEG by Using Neural Network and Wavelet Coefficients. *Expert Syst. Appl.*, 28(4):701–711, May 2005.

- [TB03] P. Thiffault and J. Bergeron. Monotony of road environment and driver fatigue: a simulator study. *Accid Anal Prev*, 35(3):381–91, 2003.
- [Toy08] Toyota. Toyota Enhances Pre-crash Safety System with Eye Monitor, 2008. Available at <https://web.archive.org/web/20160928085623/http://www.toyota.co.jp/en/news/08/0122.html>, Zugriff: 2017-04-03.
- [Vig97] Ricardo Nuno Vigário. Extraction of ocular artefacts from {EEG} using independent component analysis. *Electroencephalography and Clinical Neurophysiology*, 103(3):395 – 404, 1997.
- [VLBB11] J. Vicente, P. Laguna, A. Bartra, and R. Bailon. Detection of driver's drowsiness by means of HRV analysis. In *Computing in Cardiology, 2011*, pages 89–92, Sept 2011.
- [Vol16] Volkswagen. Müdigkeitserkennung, 2016. Available at <http://inside.volkswagen.de/Mach-mal-Pause.html>, Zugriff: 2016-10-14.
- [VRCP02] A. Vuckovic, V. Radivojevic, A. C.N. Chen, and D. Popovic. Automatic recognition of alertness and drowsiness from EEG by an artificial neural network. *Medical Engineering & Physics*, 24(5):349 – 360, 2002.
- [VTE<sup>+</sup>09] F. C. Viola, J. Thorne, B. Edmonds, T. Schneider, T. Eichele, and S. Debener. Semi-automatic identification of independent components representing EEG artifact. *Clinical Neurophysiology*, 120(5):868–877, 2009.
- [WB00] B. J. Wilson and T. D. Bracewell. Alertness monitor using neural networks for EEG analysis. In *Neural Networks for Signal Processing X, 2000. Proceedings of the 2000 IEEE Signal Processing Society Workshop*, volume 2, pages 814–820 vol.2, 2000.
- [WFKea94] W.W. Wierwille, R.J. Fairbanks, C.L. Kirn, and S.S. Wreggit et al. *Research on Vehicle-based Driver Status/performance Monitoring: Development, Validation, and Refinement of Algorithms for Detection of Driver Drowsiness*. U.S. Department of Transportation, National Highway Traffic Safety Administration, 1994.

- [WLH12] J. De Winter, P. Van Leuwen, and P. Happee. Advantages and disadvantages of driving simulators: A discussion. In *Proceedings of Measuring Behavior*, pages 47–50. Citeseer, 2012.
- [WSM15] A. Widmann, E. Schröger, and B. Maess. Digital filter design for electrophysiological data—a practical approach. *Journal of neuroscience methods*, 250:34–46, 2015.
- [YKLL16] J. J. Yan, H. H. Kuo, Y. F. Lin, and T. L. Liao. Real-time driver drowsiness detection system based on perclos and grayscale image processing. In *2016 International Symposium on Computer, Consumer and Control (IS3C)*, pages 243–246, July 2016.
- [YLC<sup>+</sup>13] C.-W. You, N. D. Lane, F. Chen, R. Wang, Z .Chen, T. J. Bao, M. Montes de Oca, Y. Cheng, M. Lin, L. Torresani, and A. T. Campbell. CarSafe App: Alerting Drowsy and Distracted Drivers Using Dual Cameras on Smartphones. In *Proceeding of the 11th Annual International Conference on Mobile Systems, Applications, and Services*, MobiSys '13, pages 13–26, New York, NY, USA, 2013. ACM.
- [ZL12] A. Zhang and F. Liu. Drowsiness detection based on wavelet analysis of ECG and pulse signals. In *Biomedical Engineering and Informatics (BMEI), 2012 5th International Conference on*, pages 491–495, Oct 2012.
- [ZLT15] L. Zhang, F. Liu, and J. Tang. Real-Time System for Driver Fatigue Detection by RGB-D Camera. *ACM Trans. Intell. Syst. Technol.*, 6(2):22:1–22:17, March 2015.

## 9 Ehrenwörtliche Erklärung

Ich versichere ehrenwörtlich:

- Ich habe diese Thesis selbstständig verfasst,
- alle benutzten Quellen und Hilfsmittel – dazu zählen auch sinngemäß übernommene Inhalte, leicht veränderte Inhalte sowie übersetzte Inhalte – in Quellenverzeichnissen, Fußnoten oder direkt bei Zitaten angegeben,
- alle wörtlichen und sinngemäßen Zitate von Textstücken, Tabellen, Grafiken, Fotos, Quellcode usw. aus fremden Quellen als solche gekennzeichnet und mit seitengenauen Quellenverweisen versehen, und
- alle nicht als Zitate gekennzeichneten Inhalte selbst erstellt.
- Ich kenne und achte den Leitfaden für gute wissenschaftliche Praxis „Wissenschaftliches Arbeiten – Leitfaden des Studiengangs Medien- und Kommunikationsinformatik, Fakultät Informatik, Hochschule Reutlingen.
- Die von mir eingereichten Dokumente und Artefakte wurden noch nicht in dieser oder ähnlicher Form einer anderen Kommission zur Prüfung vorgelegt.

Mir ist bekannt, dass unmarkierte und unbelegte wörtliche und bildliche Zitate und Paraphrasen Plagiate sind und nicht als handwerkliche Fehler, sondern als eine Form vorsätzlicher Täuschung der Prüfer gelten, indem der Plagiator fremde Gedanken als eigene Gedanken vortäuscht, um sich eine bessere Leistungsbewertung zu erschleichen.

Mir ist bekannt, dass Plagiarismus die Standards guter wissenschaftlicher Praxis, die Regeln des Studiengangs Medien- und Kommunikationsinformatik, die Studien- und Prüfungsordnung der Hochschule Reutlingen (§ 10 Täuschung und Ordnungsverstoß) und das Landeshochschulgesetz von Baden-Württemberg (§ 3 Wissenschaftliche Redlichkeit Abs. 5, § 62 Exmatrikulation Abs. 3) missachtet und seine studienrechtlichen Folgen vom Nichtbestehen bis zur Exmatrikulation reichen.

Mir ist auch bekannt, dass Plagiate sogar das Urheberrechtsgesetz (§ 51 Zitate, § 63 Quellenangabe, § 106 Unerlaubte Verwertung urheberrechtlich geschützter Werke) verletzen und zivil- und strafrechtliche Folgen nach sich ziehen können.

---

Ort,

Datum

Unterschrift (Vor- und Nachname)